



**MODELO DE APPLICATION SCORING CON ESTIMACIÓN DE
PROBABILIDAD DE INCUMPLIMIENTO (PD) A TRAVÉS DE
TÉCNICAS DE MACHINE LEARNING**

Trabajo Fin de Máster

Autor: Karim Hamed El Hadi

Tutor: José Manuel Rodríguez.

Madrid, Junio 2026

Contenido

MODELO DE APPLICATION SCORING CON ESTIMACIÓN DE PROBABILIDAD DE INCUMPLIMIENTO (PD) A TRAVÉS DE TÉCNICAS DE MACHINE LEARNING	1
Glosario	4
1. Introducción.....	5
1.1. Descripción del problema.....	5
1.2. Objetivo	5
1.2.1. Objetivos específicos	6
1.3. Caso de uso	6
1.4. Estructura de la memoria	7
1.5. Planificación y tiempo de desarrollo	7
2. Marco teórico y Estado del arte	7
2.1 Riesgo de crédito en banca	7
2.2 Application Scoring: contexto y evolución	8
2.3 Marco regulatorio como referencia (Basel III IRB, IFRS 9).....	9
2.4 De la regresión logística al Machine Learning en crédito.	9
2.5 Métricas de evaluación.	10
3. Obtención y comprensión de los datos	13
3.1. Data set HMEQ (Home Equity Loans).....	13
3.2. Calidad del dato	13
3.3. Partición train/test	17
3.4. Arquitectura de datos.....	17
4. Exploratory Data Analysis	17
4.1. Análisis de la variable objetivo	18
4.2. Análisis univariante	19
4.3. Análisis multivariante	21
4.4. Construcción de CLTV	22
4.5. Síntesis de EDA	24
5. Modelización	24
5.1. Modelo principal: Regresión Logística + WoE y binning óptimo.....	25
5.2. Benchmark 1: LightGBM	29
5.3. Benchmark 2: XGBoost.....	37
6. Validación y comparación	41
6.1. Discriminación (AUC, Gini, KS) train vs test.....	42
6.2. Curvas ROC comparadas.....	43
6.3. Calibración (Curva de calibración y Brier Score)	44

6.4.	Estabilidad poblacional (PSI)	45
6.5.	Definición del umbral operativo (cost-sensitive)	46
6.6.	Métricas operativas bajo umbral Recall / Precision / F1	46
6.7.	Score Band Report del Modelo Principal	48
6.8.	Comparativa Principal vs Benchmark	48
6.9.	Recomendación final	49
6.10.	Limitaciones	49
7.	Conclusiones.....	50
8.	Anexos.....	51
8.1.	Anexo A. Repositorio del proyecto (GitHub)	51
9.	Bibliografía.....	52

Glosario

Sigla	Significado
AUC	Area Under the ROC Curve
BCBS	Basel Committee on Banking Supervision
BCE	Banco Central Europeo
CLTV	Combined Loan-to-Value
CRR	Capital Requirements Regulation
EAD	Exposure at Default
EBA	European Banking Authority
EL	Expected Loss
GLM	Generalized Linear Model
HMEQ	Home Equity Loans
IFRS 9 / NIIF 9	International Financial Reporting Standard 9
IRB	Internal Ratings-Based
IV	Information Value
KS	Kolmogorov-Smirnov
LGD	Loss Given Default
ML	Machine Learning
MNAR	Missing Not At Random
PD	Probability of Default
PDO	Points to Double the Odds
PSI	Population Stability Index
ROC	Receiver Operating Characteristic
RWA	Risk-Weighted Assets
SHAP	SHapley Additive exPlanations
WoE	Weight of Evidence

1. Introducción

El riesgo crediticio constituye uno de los principales riesgos a los que se enfrentan las entidades financieras y se define como la posibilidad de que un prestatario no cumpla, ya sea total o parcialmente, sus obligaciones contractuales en los plazos acordados o visto desde la parte contraria, la posibilidad que corre un acreedor de sufrir pérdidas derivadas de un impago, parcial o total, de los créditos concedidos a sus clientes.

Este riesgo es especialmente relevante en la banca, ya que la concesión de crédito representa una parte sustancial de su modelo de negocio y, por tanto, su correcta medición resulta determinante para la estabilidad de la entidad.

1.1.Descripción del problema

Las sucesivas crisis financieras, y en particular la crisis financiera global de 2008, pusieron de manifiesto importantes deficiencias en la medición, gestión y supervisión del riesgo de crédito por parte de las entidades financieras. La acumulación de riesgos mal evaluados, junto con una subestimación de las pérdidas potenciales, tuvo consecuencias significativas no solo para las propias entidades, sino también para la economía real, obligando a la intervención de gobiernos y bancos centrales para garantizar la estabilidad del sistema financiero.

Como respuesta a estas crisis, los supervisores bancarios y los bancos reforzaron los marcos normativos y de supervisión de la actividad bancaria. Este refuerzo regulatorio se tradujo en una mayor exigencia en términos de capital, provisiones, así como en la necesidad de tener métricas cuantitativas sólidas que permitieran medir el riesgo de crédito asumido por las entidades.

En este contexto, se consolidó el uso de métricas fundamentales como la Probabilidad de Incumplimiento (PD), que mide la probabilidad de que un prestatario entre en situación de impago; la Pérdida en Caso de Impago o Severidad (LGD), que cuantifica la proporción de pérdida económica una vez producido el incumplimiento; y la Exposición en el Momento del Impago (EAD), que representa la exposición crediticia pendiente en el momento en que se produce el impago. El producto de estos tres parámetros permite calcular la Pérdida Esperada (EL), métrica central tanto para la gestión interna del riesgo como para el cumplimiento de los requerimientos contables y regulatorios.

El uso de técnicas avanzadas de Machine Learning ha ganado relevancia en el ámbito del riesgo de crédito, permitiendo capturar relaciones no lineales y patrones complejos en los datos y mejorando la capacidad predictiva. No obstante, estas técnicas plantean retos específicos como son la interpretabilidad de los modelos y en particular en banca, la aceptación regulatoria.

Este TFM se centra en la estimación de la Probabilidad de Incumplimiento (PD) aplicada a la originación del crédito (*application scoring*), analizando la tensión entre modelos estadísticos tradicionales donde la interpretabilidad es ampliamente aceptada y técnicas de Machine Learning de mayor capacidad predictiva pero menor transparencia.

1.2.Objetivo

Este TFM tiene como objetivo desarrollar y comparar modelos de *application scoring* para la estimación de la PD, utilizando el dataset *HMEQ (Home Equity Loans)* de

CreditRiskAnalytics.net. Este repositorio es el material de referencia del libro *Credit Risk Analytics (Baesens, Roesch & Scheule, 2016)*, bibliografía principal de este trabajo.

La muestra HMEQ recoge información a nivel de préstamo sobre operaciones de crédito con garantía hipotecaria.

1.2.1. Objetivos específicos

Objetivo 1 - Selección de modelos: Para estimar la PD de la muestra HMEQ, se construirán tres modelos de machine learning.

- a) El modelo principal, una regresión logística combinada con el Weight of Evidence (WoE) ampliamente utilizado en el sector bancario por su interpretabilidad y alineación regulatoria.
- b) Dos técnicas con mayor capacidad predictiva de gradient boosting, LightGBM y XGBoost que se emplearán como benchmark.

Objetivo 2 - Validación: Evaluar los modelos con el conjunto de métricas que cubren cuatro dimensiones:

- a) Discriminación: AUC, Gini, KS.
- b) Calibración: Brier Score
- c) Estabilidad poblacional: PSI
- d) Clasificación bajo umbral operativo: Recall, Precision, F1.

Además, el umbral se determina mediante un criterio coste-beneficio (cost-sensitive threshold).

Objetivo 3 - Comparación: Llevar a cabo un análisis estructurado principal vs. benchmark, integrando criterios de rendimiento predictivo, estabilidad poblacional y adecuación al contexto regulatorio bancario, con el fin de identificar el modelo más adecuado para su uso en un entorno real de originación de crédito.

1.3. Caso de uso

El caso de uso de este TFM se centra en la evaluación del riesgo de crédito en departamentos de riesgos de entidades financieras, donde su estimación es un elemento fundamental tanto desde la perspectiva de negocio como regulatoria.

Una estimación precisa de la PD permite a las entidades realizar una correcta asignación de provisiones por pérdidas crediticias esperadas, así como evaluar de forma adecuada el impacto económico asociado a la concesión de crédito.

En este contexto, el uso de técnicas de ML (*Machine Learning*) puede aportar mayor capacidad predictiva, capturando patrones complejos y no lineales al explotar de forma más eficiente la información disponible.

En particular, estos modelos son de aplicación directa en la originación del crédito: ante la solicitud de un préstamo con garantía hipotecaria (*home equity loan*), el modelo estima la probabilidad de impago del solicitante, apoyando la decisión de concesión o denegación de la operación.

1.4. Estructura de la memoria

El trabajo se estructura en siete capítulos. En el capítulo 2 se presenta el estado del arte, en lo que se refiere a la evolución de los modelos de estimación de PD, desde enfoques estadísticos clásicos hasta técnicas de *Machine Learning*.

El capítulo 3 describe los datos utilizados, sus fuentes, principales variables y procesos de limpieza y preparación de los datos.

El capítulo 4 se lleva a cabo el análisis exploratorio de los datos (EDA), con el objetivo de comprender la distribución y relación tanto de la variable objetivo como las variables explicativas apoyado por visualizaciones.

El capítulo 5 muestra la modelización y evaluación de las técnicas de ML empleadas para la estimación de PD estableciendo un modelo principal y dos modelos boosting (LightGBM y XGBoost) para comparar.

El capítulo 6 recoge la validación de los modelos y su comparación en formato principal vs benchmark.

El Capítulo 7 establece las conclusiones de trabajo y plantea las líneas de trabajo futuro, proponiendo posibles extensiones y mejoras del enfoque desarrollado.




Figura 1. Estructura de la memoria por bloques.

1.5. Planificación y tiempo de desarrollo

El desarrollo del trabajo se ha organizado siguiendo las fases con CRISP-DM. Esta estructura ordena el proyecto desde la comprensión del problema y de los datos hasta la modelización y su evaluación, y es la que vertebra los capítulos de esta memoria. La Tabla X resume las tareas principales de cada fase y la dedicación aproximada, que asciende a unas 150 horas.

Fase (CRISP-DM)	Tareas principales	Horas
Comprensión del negocio	Definición del problema, objetivos, marco teórico y estado del arte	16
Comprensión de los datos	Análisis exploratorio, calidad del dato, estudio de missing y outliers	20
Preparación de los datos	Tratamiento de missing, construcción de CLTV, binning óptimo y WoE, pipelines	30
Modelización	Regresión logística con WoE, LightGBM y XGBoost, búsqueda de hiperparámetros, monotonía y SHAP	40
Evaluación	Validación, métricas de discriminación, calibración y estabilidad, comparación de modelos	24
Redacción de la memoria	Redacción, revisión y elaboración de figuras y tablas	20
Preparación de la defensa	Presentación y ensayo	10
Total		160

Tabla 1. CRISP-DM

2. Marco teórico y Estado del arte

2.1 Riesgo de crédito en banca

Los bancos reciben flujos de caja de diferentes fuentes. La más importante son los depósitos incluyendo cuentas de ahorro o plazo fijo y a cambio, los depositantes reciben

un interés fijo o variable. Hay otras fuentes como el capital de los accionistas que adquieren una propiedad del banco. A cambio, la entidad debe conseguir beneficios y compensar al accionista a través de dividendos.

Por el lado de los activos, los bancos emplean el dinero obtenido para prestarlo a deudores que necesitan el dinero para multitud de fines, comprar una casa, financiar los estudios, un coche, etc. Además, el banco realiza otras inversiones como son la inversión en mercados financieros (acciones o bonos).

Estas inversiones que realiza el banco tienen un riesgo asociado y dado el impacto social de los bancos en el sistema económico, deben gestionar adecuadamente los riesgos a los que se exponen.

Es por ello por lo que los bancos han desarrollado procesos de evaluación del riesgo. Los acuerdos de Basilea cubren principalmente tres tipos de riesgo. El primero es el riesgo de mercado, o riesgo de sufrir pérdidas derivadas de movimientos adversos en los mercados financieros. El segundo es el riesgo operacional que, a diferencia de los demás, no es un riesgo financiero, sino que resulta de fallos en procesos internos, sistemas o personas. El tercero, y el que concierne a este trabajo, es el riesgo de crédito.

El tercero, y el que concierne a este trabajo, es el riesgo de crédito, que trata de medir la probabilidad de incumplimiento y las pérdidas asociadas a los activos crediticios. Su gestión abarca todo el ciclo de vida del crédito: desde la originación, donde se evalúa la solvencia del solicitante antes de conceder la operación; el seguimiento, donde se monitoriza el comportamiento del deudor durante la vida del préstamo; hasta la recuperación, donde se gestionan las posiciones en situación de impago. Este trabajo se centra en la fase de originación, estimando la probabilidad de incumplimiento en el momento de la solicitud mediante técnicas de *application scoring* (Baensens et al., 2016).



Figura 2. Fases del ciclo de vida del riesgo de crédito

2.2 Application Scoring: contexto y evolución

El objetivo del *application scoring* o scoring de admisión es la asignación de una puntuación que refleje el riesgo de crédito del solicitante del préstamo, ayudando a la entidad a decidir si concede o deniega la operación.

Históricamente, estas decisiones se tomaban de forma manual por analistas de riesgo, basándose en criterios subjetivos y con escasa consistencia entre decisores. La incorporación de enfoques estadísticos multivariantes permitió objetivar y sistematizar este proceso: a partir de los datos del solicitante, se estima la probabilidad de incumplimiento y mediante técnicas de transformación *Weight of Evidence/scorecard* (WoE) se traduce en una puntuación numérica interpretable. Sobre ello, un criterio coste-beneficio (*cost-sensitive threshold*) fija el umbral de decisión.

La evolución posterior hacia técnicas de Machine Learning ha permitido capturar relaciones no lineales entre variables y mejorar la capacidad predictiva de los modelos, manteniendo como referencia el enfoque estadístico clásico por su interpretabilidad y aceptación regulatoria. La principal ventaja del *application scoring* frente a la decisión

manual reside en su velocidad, consistencia y escalabilidad: permite evaluar miles de solicitudes de forma homogénea y trazable.

2.3 Marco regulatorio como referencia (Basel III IRB, IFRS 9)

En este apartado se da relevancia a la rama regulatoria ya que actúa como marco de referencia para las entidades financieras acerca de cómo modelar el riesgo de crédito. Por lo tanto, el cálculo del riesgo de crédito se convierte en una obligación no solo de gestión interna sino también regulatoria.

En concreto, los acuerdos de Basilea III plantean un enfoque estándar (*Standardized Approach*) basado en activos ponderados por riesgo (*RWA*) y el enfoque IRB (*Internal Ratings Based*) más sofisticado para cuantificar el riesgo crediticio. Su cálculo se apoya en una serie de parámetros donde la PD se incluye y es clave en este TFM. A él se suma la severidad (LGD) el cual es la proporción de la exposición que no se recupera en caso de impago y el Exposure at Default (EAD) o exposición crediticia en el momento del impago.

Dentro de IRB, la PD está estimada por la entidad, pero cabe distinguir que existe el enfoque FIRB (*IRB Foundation*), LGD y EAD son prescritos por el supervisor, mientras que en el enfoque AIRB (*IRB Advanced*) la entidad los estima internamente tras la aprobación del supervisor. (*Basel Committee on Banking Supervision, 2017*)

La elección del enfoque determina el grado de sofisticación en la estimación del capital regulatorio.

Por su parte, la norma contable IFRS 9 (*International Financial Reporting Standard 9*), en vigor desde 2018, exige el reconocimiento anticipado de las pérdidas crediticias esperadas (*Expected Credit Loss, ECL*) mediante un modelo de tres fases (*stages*) según el deterioro crediticio del activo. La PD es el parámetro central: en Stage 1 (sin aumento significativo del riesgo desde el reconocimiento inicial) se estima la ECL a 12 meses; en Stage 2 (incremento significativo del riesgo, *SICR*) y Stage 3 (activo deteriorado) se estima a lo largo de toda la vida de la operación (*lifetime*).

Ambos marcos exigen modelos de PD robustos, validados y suficientemente explicables para su revisión supervisora. Esta exigencia justifica mantener el modelo estadístico clásico (regresión logística con WoE) como referencia regulatoria, al tiempo que se evalúa la incorporación de técnicas de ML de mayor capacidad predictiva.

2.4 De la regresión logística al Machine Learning en crédito.

La regresión logística es muy popular en modelos de admisión de riesgo de crédito debido principalmente a su simplicidad y buen rendimiento, pero también a su interpretabilidad ya que permite evaluar los signos de los coeficientes de cada variable y además puede transformarse fácilmente en una tabla de puntuación (*scorecard*) lo que facilita su implementación operativa en entornos bancarios. Además, su combinación con la transformación *Weight of Evidence* (WoE) permite discretizar las variables continuas en intervalos con comportamiento de riesgo homogéneo, facilitando la detección de relaciones no lineales de variables y en definitiva mejorando la separación entre “buenos y malos” pagadores. El WoE además aporta una interpretación directa de cada banda de la variable en términos de riesgo relativo.

Con el avance de las técnicas de ML, los modelos han ganado presencia en la estimación del riesgo de crédito. Los algoritmos basados en árboles de decisión, como las técnicas de *gradient boosting* (*LightGBM* y *XGBoost*) han demostrado una mayor capacidad predictiva frente a la regresión logística, al capturar relaciones no lineales y patrones complejos en los datos sin necesidad de transformaciones previas como el WoE.

Sin embargo, esta mayor capacidad predictiva conlleva una reducción significativa de la interpretabilidad del modelo. En entornos bancarios regulados esto representa un obstáculo relevante. El CRR (Art. 179) exige que las estimaciones de los parámetros IRB sean plausibles, intuitivas y basadas en los factores de riesgo materiales, lo que en la práctica favorece modelos cuya lógica sea trazable y auditable. La propia EBA ha abordado el uso de *Machine Learning* en modelos IRB mediante recomendaciones basadas en principios, sin prohibirlo, pero subrayando la necesidad de explicabilidad. Un modelo de *gradient boosting* en producción IRB requeriría, por tanto, una capa adicional de explicabilidad.

Adicionalmente, en el contexto regulatorio no solo importa la capacidad de ordenar correctamente a los solicitantes (AUC o el KS), sino que la PD estimada sea una probabilidad real y creíble. Esta propiedad, conocida como calibración, es fundamental bajo Basilea III: una PD mal calibrada afecta directamente al cálculo de los activos ponderados por riesgo y, en consecuencia, a los requerimientos de capital.

Para mitigar el problema de interpretabilidad en modelos de ML se recurre a dos vías complementarias.

- La primera, técnicas de explicabilidad *post-hoc* como SHAP (*Shapley Additive explanations*), que descomponen la predicción de un modelo ya entrenado en la contribución individual de cada variable.
- La segunda, la imposición de restricciones de monotonía durante el entrenamiento, que obliga a que la relación entre cada variable y la PD estimada siga una dirección coherente con el sentido de negocio (por ejemplo, que a mayor ratio de endeudamiento la PD no disminuya). Ambas acercan el *gradient boosting* a la exigencia de explicabilidad regulatoria, aunque no eliminan por completo la brecha frente a la transparencia nativa de la regresión logística con WoE.

2.5 Métricas de evaluación.

La evaluación de modelos de PD requiere un conjunto de métricas que cubran distintas dimensiones del rendimiento. En la literatura de *credit scoring* (Baesens et al., 2016) se distinguen habitualmente tres dimensiones principales: discriminación, calibración y estabilidad. A estas se añade, en contexto operativo, la clasificación bajo umbral, que se desarrolla en el apartado siguiente junto con el análisis de errores de clasificación.

2.5.1. Discriminación

Las métricas de discriminación miden la capacidad del modelo para ordenar correctamente a los solicitantes según su riesgo, separando buenos de malos pagadores. Aquí encontramos:

- El AUC-ROC (*Area Under the ROC Curve*) representa el área bajo la curva ROC, que enfrenta la tasa de verdaderos positivos (*Recall*) frente a la tasa de falsos

positivos para todos los umbrales posibles. Un AUC de 0.5 equivale a un modelo aleatorio; un AUC de 1.0 indica discriminación perfecta. En *credit scoring* bancario, valores superiores a 0.75 se consideran aceptables y valores superiores a 0.80 buenos (Baesens et al., 2016).

- El coeficiente de Gini es una transformación lineal del AUC: $Gini = 2 \times AUC - 1$. Toma valores entre 0 y 1, siendo 0 un modelo sin poder discriminante y 1 discriminación perfecta.
- El KS (*Kolmogorov-Smirnov*) mide la máxima distancia entre la distribución acumulada de buenos y malos pagadores a lo largo de todos los umbrales posibles. Cuanto mayor es el KS, mayor es la capacidad del modelo para separar ambas poblaciones en el punto óptimo de corte.

2.5.2. Calibración

Las métricas de calibración evalúan si las probabilidades estimadas por el modelo corresponden a frecuencias de impago reales observadas. Es decir, si una PD estimada del 20% se corresponde efectivamente con un 20% de impagos en ese grupo.

- El Brier Score mide el error cuadrático medio entre la probabilidad estimada y el resultado binario observado (0 o 1). Toma valores entre 0 y 1, siendo 0 el modelo perfecto. Es sensible tanto a la discriminación como a la calibración, penalizando predicciones alejadas del resultado real.
- La curva de calibración representa gráficamente la probabilidad media estimada frente a la frecuencia de impago observada en cada decil de la distribución. Un modelo perfectamente calibrado sigue la diagonal. Las desviaciones sistemáticas indican sobreestimación o infraestimación del riesgo.

2.5.3. Estabilidad poblacional

El PSI (*Population Stability Index*) mide el grado de desplazamiento de la distribución de puntuaciones entre la muestra de desarrollo del modelo y una muestra posterior, detectando cambios en el perfil de la población.

A diferencia de discriminación y calibración que evalúan el modelo en su desarrollo, PSI está orientada al seguimiento y control post-implantación, cuyo objetivo es detectar si la población sobre la que se aplica el modelo ha evolucionado respecto a “train”. Un valor elevado puede requerir recalibrar o sustituir el modelo.

Se calcula como:

$$PSI = \sum_{i=1}^n (A_i - E_i) \times \ln \left(\frac{A_i}{E_i} \right)$$

donde A_i es la proporción observada en cada banda y E_i la proporción esperada. Convencionalmente, $PSI < 0.10$ indica estabilidad, entre 0.10 y 0.25 requiere monitorización y superior a 0.25 indica un cambio poblacional significativo que puede invalidar el modelo.

2.5.4. Errores de clasificación y clasificación bajo umbral operativo

Los modelos de estimación de PD producen una probabilidad continua entre 0 y 1. Para traducir en una decisión binaria (conceder o denegar el crédito) es necesario establecer

un umbral operativo o *threshold*. La elección de este umbral determina directamente los errores de clasificación del modelo.

En el contexto de clasificación crediticia se distinguen dos tipos de error:

El error de tipo I o falso positivo (FP) se produce cuando el modelo clasifica a un solicitante como mal pagador cuando en realidad habría pagado correctamente. El coste para la entidad es la pérdida del margen financiero de una operación rentable que no se concede.

El error de tipo II o falso negativo (FN) se produce cuando el modelo clasifica a un solicitante como buen pagador cuando en realidad incumplirá. El coste para la entidad es la pérdida crediticia derivada de una operación concedida que entra en impago.

		Matriz de confusión	
		Valor real	
		Impaga (BAD = 1)	Paga (BAD = 0)
Predicción del modelo	Impaga	Verdadero Positivo (TP) Mal pagador detectado	Falso Positivo (FP) Buen pagador rechazado Error tipo I
	Paga	Falso Negativo (FN) Mal pagador no detectado Error tipo II	Verdadero Negativo (TN) Buen pagador aprobado

Figura 3. Matriz de confusión

En entornos crediticios, ambos errores no tienen el mismo coste. El coste de un FN (conceder crédito a un mal pagador) es superior al coste de un FP (rechazar a un buen pagador), lo que justifica el uso de un criterio coste-beneficio (*cost-sensitive threshold*) para la determinación del umbral operativo.

A partir de la matriz de confusión resultante de aplicar el umbral, se calculan las métricas de clasificación. El Recall o sensibilidad mide la proporción de malos pagadores correctamente identificados sobre el total de malos pagadores reales. La Precisión mide la proporción de predicciones de impago que son correctas sobre el total de predicciones positivas. El F1-Score es la media armónica de ambas, ofreciendo un balance entre las dos métricas:

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Es importante señalar, siguiendo a Iván Pastor Sanz, que en modelos de PD bajo enfoque IRB, el umbral operativo no lo define el modelo sino la política de crédito de la entidad. Por tanto, Recall, Precisión y F1 deben considerarse métricas complementarias orientativas, no el criterio de selección del modelo principal.

3. Obtención y comprensión de los datos

Se ha utilizado una muestra de datos orientados al análisis y modelización del riesgo de crédito. Los datos proceden del libro *Credit Risk Analytics* (Baesens, Roesch & Scheule, 2016), referencia bibliográfica principal de este trabajo. ⁱ

En concreto, se emplea uno de los datasets disponibles, *Home Equity Loan (HMEQ)*, orientado a la modelización del impago en operaciones de crédito hipotecario con garantía (*home equity*).

En este capítulo, se aborda la estructura general de la muestra, la tipología y agrupación funcional de las variables y finalidad analítica con la que se incorporan al proyecto.

3.1.Data set HMEQ (Home Equity Loans)

HMEQ está compuesto por 5.960 observaciones y 13 variables, y recoge información de solicitudes de préstamo con garantía hipotecaria. Combina variables numéricas continuas, variables categóricas y variables de conteo, así como una variable target binaria que indica la ocurrencia de impago.

El objetivo principal, ante este problema de clasificación supervisada, es modelizar la PD representada por la variable BAD (apartado 1.2).

Las variables del dataset se agrupan en cuatro categorías funcionales en función de la información que aportan al modelo: la variable objetivo, variables financieras, variables de comportamiento crediticio y variables sociodemográficas y laborales. La Tabla 1 recoge la clasificación completa.

Grupo funcional	Variable	Tipo de variable	Descripción
Objetivo	BAD	Binaria	Indica si el cliente ha incumplido (1) o no (0) en el pago del préstamo
Financieras	LOAN	Númerica continua	Importe del préstamo solicitado
Financieras	MORTDUE	Númerica continua	Saldo pendiente de la hipoteca existente
Financieras	VALUE	Númerica continua	Valor estimado de la propiedad
Financieras	DEBTINC	Númerica continua	Ratio deuda-ingresos del prestatario
Comportamiento crediticio	DEROG	Conteo	Número de incidencias crediticias graves
Comportamiento crediticio	DELINQ	Conteo	Número de líneas de crédito en mora
Comportamiento crediticio	NINQ	Conteo	Número de consultas recientes de crédito
Comportamiento crediticio	CLAGE	Númerica continua	Antigüedad de la línea de crédito más antigua (meses)
Comportamiento crediticio	CLNO	Conteo	Número total de líneas de crédito
Sociodemográficas / laborales	YOJ	Númerica continua	Años en el empleo actual
Sociodemográficas / laborales	JOB	Categórica	Categoría ocupacional del prestatario
Sociodemográficas / laborales	REASON	Categórica	Finalidad del préstamo (consolidación de deuda o mejora del hogar)

Tabla 1. Clasificación funcional de variables en el dataset HMEQ.

Fuente: elaboración propia a partir de Baesens et al. (2016). La variable CLTV no figura en el dataset original; se construye en el apartado 4.4 a partir de LOAN, MORTDUE y VALUE.

Todas las variables son observables en el momento de la solicitud, ya sea como información declarada por el prestatario o como datos extraídos del historial crediticio.


3.2.Calidad del dato

En esta sección se analiza los valores faltantes o *missing values* y los valores extremos o *outliers*.

3.2.1. Missing values

El conjunto de datos presenta características habituales en entornos reales de riesgo de crédito, como la presencia de missing values y valores extremos, lo que refuerza su idoneidad para un análisis orientado a la calidad del dato y a la interpretabilidad de los modelos.

Todas las variables excepto BAD y LOAN presentan valores missing:



Gráfica 1. Porcentaje de missing values por variable

Destaca el ratio deuda-ingresos (DEBTINC) con un 21.26% de valores faltantes. Esta situación es coherente con la realidad bancaria, donde la información de ingresos puede no estar disponible, ser incompleta o no verificable en determinados clientes.

Variables de comportamiento crediticio como DEROG (*derogatory reports*, 12 %) y DELINQ (*delinquencies*, 10 %) también presentan missing values, lo que resulta especialmente relevante desde una perspectiva de riesgo, al tratarse de indicadores clave para la identificación de historiales de mora o incidencias graves.

La presencia de nulos en este tipo de variables sugiere que los valores faltantes no pueden asumirse como completamente aleatorios, por lo que su tratamiento deberá evaluarse cuidadosamente en la fase de preprocesamiento.

El TFM analiza los posibles mecanismos de generación de valores faltantes (MCAR, MAR y MNAR), cuya correcta identificación resulta crítica para evitar sesgos en la estimación de la PD.

- MCAR (Missing Completely At Random): la ausencia es completamente aleatoria, no relacionada ni con el incumplimiento (BAD) ni con otras variables del dataset.
- MAR (Missing At Random): la ausencia está condicionada por otras características observables del cliente, pero no por el propio valor no observado.
- MNAR (Missing Not At Random): la ausencia está relacionada con el propio valor no observado o con el nivel de riesgo del cliente; en este caso el missing contiene información implícita de riesgo.

Para distinguir estos mecanismos se aplican dos comprobaciones empíricas.

La primera contrasta el porcentaje de missing entre clientes al corriente de pago (BAD=0) y en impago (BAD=1): una concentración del missing en los impagos apunta a MNAR

La **Tabla 2** recoge el porcentaje de missing global y por clase, junto con el mecanismo asignado a cada variable.

Variable	% Missing global	% Missing BAD=0	% Missing BAD=1
DEBTINC	21,26	10,08	66,11
DEROG	11,88	13,02	7,32
DELINQ	9,73	10,65	6,06
MORTDUE	8,69	8,64	8,92
YOJ	8,64	9,43	5,47
NINQ	8,56	9,12	6,31
CLAGE	5,17	4,82	6,56
JOB	4,68	:	:
REASON	4,23	:	:
CLNO	3,72	3,54	4,46
VALUE	1,88	0,15	8,83

Tabla 2. Porcentaje de missing values por variable respecto target

La segunda analiza la co-ocurrencia de ausencias entre variables: si dos variables tienden a faltar a la vez, su ausencia comparte un origen común (MAR).

	MORTDUE	VALUE	REASON	JOB	YOJ	DEROG	DELINQ	CLAGE	NINQ	CLNO	DEBTINC
MORTDUE	100.0	5.2	16.0	18.9	37.8	31.1	34.6	20.3	31.3	15.6	22.4
VALUE	24.1	100.0	17.9	15.2	10.7	25.0	21.4	17.0	17.0	16.1	72.3
REASON	32.9	7.9	100.0	42.5	41.3	37.3	38.1	42.1	38.9	33.7	22.2
JOB	35.1	6.1	38.4	100.0	35.8	51.6	47.3	55.2	51.6	47.3	16.1
YOJ	38.1	2.3	20.2	19.4	100.0	34.4	37.7	26.0	37.3	22.7	16.7
DEROG	22.7	4.0	13.3	20.3	25.0	100.0	71.0	31.4	56.8	31.4	18.4
DELINQ	30.9	4.1	16.6	22.8	33.4	86.7	100.0	38.3	73.6	38.3	17.9
CLAGE	34.1	6.2	34.4	50.0	43.5	72.1	72.1	100.0	72.1	72.1	26.3
NINQ	31.8	3.7	19.2	28.2	37.6	78.8	83.7	43.5	100.0	43.5	18.4
CLNO	36.5	8.1	38.3	59.5	52.7	100.0	100.0	100.0	100.0	100.0	26.1
DEBTINC	9.2	6.4	4.4	3.6	6.8	10.3	8.2	6.4	7.4	4.6	100.0

Tabla 3. Co-ocurrencia de missing values por variable

Los resultados permiten clasificar los mecanismos de la siguiente manera:

- **MNAR** : DEBTINC y VALUE: su ausencia se concentra en los impagos (DEBTINC 66,11 % en BAD=1 frente a 10,08 % en BAD=0; VALUE 8,83 % frente a 0,15 %), por lo que el patrón de missing contiene señal directa de riesgo.
- **MAR** : DEROG, DELINQ, NINQ y CLNO: tienden a faltar de forma conjunta (co-ocurrencias del 71 % al 100 %), lo que indica un origen común en su ausencia. Además, su missing es mayor en los clientes al corriente de pago, patrón opuesto al esperado en un MNAR de riesgo.
- **MCAR** : MORTDUE, YOJ, JOB, REASON y CLAGE: su porcentaje de ausencia es similar entre clases, compatible con un mecanismo aleatorio respecto a la variable objetivo.

En consecuencia, el preprocesamiento evita imputaciones puramente aleatorias en las variables con señal de riesgo. Para las variables MNAR (DEBTINC y VALUE) se preserva la información del patrón de ausencia. En el modelo principal (WoE + regresión logística), mediante una categoría

específica de *missing* en el *binning*. En el benchmark **LightGBM**, mediante su tratamiento nativo de los valores ausentes: en cada división, el algoritmo aprende la dirección óptima para los NaN minimizando la función de pérdida, de modo que cuando la ausencia está correlacionada con el impago, como ocurre en DEBTINC, ese enrutamiento captura señal de riesgo.

3.2.2. Outliers

La segmentación de los valores extremos por la variable objetivo (BAD) muestra que, en la mayoría de variables de comportamiento crediticio, los outliers presentan una tasa de impago muy superior a la del resto de registros.




Gráfico 2. Boxplots outliers por target

El caso más marcado es DEBTINC, cuyos outliers tienen una tasa de impago del 100 % frente al 7,9 % del resto; le siguen DEROG (+31 pp), DELINQ (+31 pp) y NINQ (+25 pp).

Variable	% outliers	Tasa BAD outliers (%)	Tasa BAD normal (%)	Diferencia (pp)
DEBTINC	0.59	100.00	7.90	92.10
DEROG	12.16	48.00	16.66	31.34
DELINQ	20.15	44.46	13.95	30.51
NINQ	2.97	44.63	19.63	25.00
CLNO	3.67	25.57	19.57	6.00
MORTDUE	3.93	23.93	19.72	4.21
LOAN	4.30	22.27	19.85	2.42
VALUE	5.37	20.31	18.43	1.88
YOJ	1.53	15.38	20.73	-5.35
CLAGE	0.79	6.38	19.77	-13.39

Tabla 4. Tasa de outliers por target

Este patrón indica que, en estas variables, los outliers contienen información de riesgo y no responden a errores de calidad del dato, sino a situaciones crediticias adversas. No obstante, no es un comportamiento universal: en YOJ y CLAGE los outliers presentan una tasa de impago inferior a la media, por lo que la asociación outlier-riesgo es específica de cada variable.

En consecuencia, en la fase de preprocesamiento no se eliminan los valores extremos, con el objetivo de preservar la señal de riesgo y no deteriorar la capacidad predictiva del modelo.

3.3.Partición train/test

La muestra HMEQ se divide en dos conjuntos: entrenamiento (train) y validación (test), siguiendo una partición 70/30. El conjunto de entrenamiento (70%, 4.172 observaciones) se emplea para la estimación de los parámetros de cada modelo, mientras que el conjunto de test (30%, 1.788 observaciones) se reserva para la evaluación del rendimiento fuera de muestra.

La partición se realiza mediante muestreo estratificado por la variable objetivo BAD, garantizando que la proporción de impagos se mantiene constante en ambos conjuntos. Esto es especialmente relevante en datasets con desbalance de clases, como HMEQ, donde la tasa de impago es aproximadamente del 20 %. No se aplica ninguna técnica de balanceo (oversampling, SMOTE ni undersampling) en ningún conjunto: la estratificación preserva la distribución real, de modo que la evaluación se realiza siempre sobre la proporción de impagos observada. Todos los modelos desarrollados comparten la misma partición (`random_state = 123`), lo que garantiza la comparabilidad de los resultados en el Capítulo 6.

Adicionalmente, durante la fase de optimización de hiperparámetros de los modelos de *gradient boosting* se emplea validación cruzada de cinco pliegues (*5-fold cross-validation*) mediante *GridSearchCV*, aplicada sobre el conjunto de entrenamiento. Las transformaciones de preprocesamiento (*binning* WoE, imputación) se ajustan exclusivamente sobre *train* y se aplican después a *test*, de modo que el conjunto de test permanece reservado en todo momento para la evaluación final. Con ello se evita cualquier filtración de información (*data leakage*) entre las fases de desarrollo y validación.

3.4.Arquitectura de datos

El proyecto parte de una única fuente, el dataset HMEQ en formato plano descargado de CreditRiskAnalytics.net, y lo lleva hasta los modelos a través de una cadena de notebooks de Python que reproduce las fases de preparación, modelización y evaluación.

El procesamiento se organiza en cinco notebooks encadenados, uno por etapa. El primero hace el análisis exploratorio y fija las decisiones de calidad del dato. Los tres siguientes construyen cada modelo, el principal con WoE y regresión logística y los dos benchmark de boosting. El último recupera los modelos ya entrenados y los compara. Las transformaciones que se reutilizan entre notebooks, como el CLTVTransformer, no se redefinen en cada uno; viven en un módulo compartido, `src/transformers.py`, y se importan donde hagan falta. Esto evita duplicar código y, sobre todo, permite que los pipelines serializados se recarguen sin tener que reconstruir las clases a mano.

Cada modelo entrenado se guarda con joblib en la carpeta `models/`, de modo que el notebook de comparación los carga desde ahí en lugar de reentrenar. Todo el flujo está versionado en un repositorio público de GitHub, que recoge los notebooks, el módulo de transformaciones, los modelos serializados y los datos.

4. Exploratory Data Analysis

En este capítulo se hace uso de la metodología EDA para obtener los primeros hallazgos y familiaridad con los datos. En este capítulo se lleva a cabo un análisis univariante y un análisis multivariante poniendo especial atención en la variable objetivo (BAD).

A través del análisis univariante, se lleva a cabo una exploración de cada distribución, asimetría y comprensión de sus estadísticas descriptiva. En cambio, en el multivariante, llevaremos a cabo el análisis conjunto observando correlaciones y dependencias.

Por último, se realizarán visualizaciones de las distribuciones y composición de las variables a través de histogramas y boxplots poniendo especial atención a su relación con la variable objetivo.

Tras el análisis se tomarán decisiones sobre el tratamiento o enriquecimiento de los datos.

El análisis se desarrolla en el notebook 01_EDA_HMEQ.ipynb, disponible en el repositorio público del proyecto (véase Anexo A), y su estructura se resume en la Figura 2.



Figura 4. Estructura de EDA

4.1. Análisis de la variable objetivo

La variable objetivo BAD es una binaria donde 0 es al corriente de pago y 1 es default o impago. Es un problema de clasificación binaria donde todas las variables empleadas por los modelos buscan predecir el resultado de BAD.

En este caso es un problema claramente desbalanceado donde, tal y como se observa en la siguiente figura, la distribución de BAD contiene un 80,05% de los registros “buenos” y 19,95% de “malos” (datos globales)




Gráfico 3. Distribución target

Tratándose de un problema de clasificación binaria y desbalanceado, se evitará usar métricas como el accuracy. Por este motivo, métricas como *Recall*, *Precisión* y *F1* son ideales para evaluar la correcta clasificación del modelo donde se puede observar como un fallo en *Recall* implica asumir una pérdida crediticia directa prediciendo un cliente bueno cuando es default (*False Negative*) o un fallo de precisión implica coste de oportunidad al rechazar un cliente solvente (*False Positive*).

No obstante, el objetivo del TFM no es solo clasificar, sino estimar la probabilidad de incumplimiento (PD), un valor numérico entre 0 y 1. Para evaluar esa estimación se emplean métricas de discriminación, que miden la capacidad del modelo de ordenar el riesgo con independencia del umbral (AUC-ROC, Gini y KS), y de calibración, que evalúan si la probabilidad estimada es creíble (Brier Score). Estas últimas son especialmente relevantes en modelos IRB,

donde la PD debe ser creíble y no solo discriminante. Su uso responde tanto a criterios técnicos como al contexto regulatorio en el que se enmarcan los modelos de PD (véase apartado 2.5).

4.2. Análisis univariante

Este apartado se centra en las estadísticas de cada variable por separado considerando, primero, la tipología (discreta o continua) de cada variable identificada en la Tabla 1 del Capítulo 3. Se analizan diferentes medidas:

- Medidas de centralización: media y mediana.
- Medidas de dispersión: desviación típica
- Medidas de localización: IQR o rango intercuartílico.
- Medidas de forma: asimetría y curtosis

Por último, las distribuciones a través de histogramas de cada variable continua y barras para variables discretas.

El análisis completo se desarrolla en el notebook 01_EDA_HMEQ.ipynb.

4.2.1. Medidas de centralización, dispersión y localización

A través del método describe (Tabla 5) se obtienen las principales medidas estadísticas y se extraen las primeras conclusiones.

	BAD	LOAN	MORTDUE	VALUE	YOJ	DEROG	DELINQ	CLAGE	NINQ	CLNO	DEBTINC
count	5960.00	5960.00	5442.00	5848.00	5445.00	5252.00	5380.00	5652.00	5450.00	5738.00	4693.00
mean	0.20	18607.97	73760.82	101776.05	8.92	0.25	0.45	179.77	1.19	21.30	33.78
std	0.40	11207.48	44457.61	57385.78	7.57	0.85	1.13	85.81	1.73	10.14	8.60
min	0.00	1100.00	2063.00	8000.00	0.00	0.00	0.00	0.00	0.00	0.00	0.52
25%	0.00	11100.00	46276.00	66075.50	3.00	0.00	0.00	115.12	0.00	15.00	29.14
50%	0.00	16300.00	65019.00	89235.50	7.00	0.00	0.00	173.47	1.00	20.00	34.82
75%	0.00	23300.00	91488.00	119824.25	13.00	0.00	0.00	231.56	2.00	26.00	39.00
max	1.00	89900.00	399550.00	855909.00	41.00	10.00	15.00	1168.23	17.00	71.00	203.31

Tabla 5 – Análisis de estadísticas descriptivas.

Atendiendo a la diferencia entre media y mediana, se observa asimetría positiva en las variables de comportamiento crediticio DELINQ, DEROG y NINQ. Esto sugiere una elevada concentración de observaciones en cero y unos pocos prestatarios con valores altos de líneas en mora, incidencias crediticias o número de consultas de crédito. En menor medida, presentan también cola positiva el número total de líneas de crédito (CLNO) y su antigüedad (CLAGE).

Esta cola positiva se repite en las variables financieras MORTDUE (saldo pendiente de la hipoteca) y VALUE (valor de la propiedad), donde la media supera a la mediana. La asimetría es más moderada en LOAN y en la antigüedad laboral (YOJ), donde la diferencia entre media y mediana es menor, aunque la presencia de valores extremos sigue siendo relevante.

La dispersión confirma la presencia de casos extremos: DEROG y DELINQ presentan desviaciones típicas de 0,85 y 1,13 frente a medias de 0,25 y 0,45, respectivamente, muy por encima de su valor central.

En conjunto, el análisis de centralización, dispersión y localización evidencia la existencia de valores extremos que tienden a concentrar un mayor número de impagos. Esto conecta con el apartado 3.2 (Calidad del dato), donde el estudio en profundidad de los outliers confirma que no son ruido estadístico ni errores de captura, sino señal de riesgo asociada a situaciones crediticias adversas.

4.2.2. Medidas de forma: asimetría y curtosis

A continuación, se muestra la distribución por histogramas y su curtosis para su análisis en este apartado.




Gráfico 4. Distribución de las variables continuas con curva normal de referencia y exceso de curtosis.

Los histogramas confirman lo analizado en el apartado anterior: distribuciones asimétricas positivas, con masa concentrada en valores bajos y colas extendidas hacia la derecha.

Atendiendo al exceso de curtosis (que en una distribución normal es 0), la mayoría de variables son leptocúrticas, con colas más pesadas que una normal, lo que indica que eventos poco frecuentes pueden tener un impacto desproporcionado en el riesgo de crédito. Los valores más altos corresponden a DEBTINC (50,45), DEROG (36,84), VALUE (24,34) y DELINQ (23,54). De estas, DEBTINC, DEROG y DELINQ son además las de mayor diferencial de tasa de impago en la cola superior (apartado anterior), lo que refuerza que sus valores extremos no son anomalías estadísticas, sino observaciones de alto riesgo. VALUE, en cambio, presenta colas pesadas sin esa asociación con el impago, coherente con su naturaleza de variable financiera.

La única excepción es YOJ (0,37), con un exceso de curtosis próximo a cero (distribución mesocúrtica, similar a la normal), consistente con su papel de factor protector frente al impago identificado anteriormente.

4.2.3. Variables categóricas

HMEQ contiene dos variables categóricas: REASON, la finalidad del préstamo (mejoras en el hogar o consolidación de deudas), y JOB, con seis categorías de empleo.

Atendiendo al porcentaje de BAD en cada categoría de REASON, la diferencia entre HomImp y DebtCon es de apenas unos puntos porcentuales, próxima a la tasa global, por lo que el poder discriminante limitado. JOB, en cambio, muestra mayor capacidad de separación: categorías

como Sales y Self presentan tasas de impago muy por encima de la media, mientras que, al igual que CLAGE o YOJ en el análisis anterior, Office y ProfExe quedan por debajo, actuando como factores de menor riesgo.

Variable	Categoría	Tasa de impago (%)
REASON	HomeImp	22.25
REASON	DebtCon	18.97
JOB	Sales	34.86
JOB	Self	30.05
JOB	Mgr	23.34
JOB	Other	23.20
JOB	ProfExe	16.61
JOB	Office	13.19

Tabla 6 – Distribución de BAD en variables categóricas.

Se adoptan dos decisiones para el Capítulo 5. REASON, por su escaso poder discriminante, no se incorpora finalmente a los modelos; no obstante, esta decisión se respalda formalmente en el Capítulo 5 mediante su Information Value (IV), que cuantifica su capacidad predictiva. JOB, por su mayor capacidad de separación, sí se conserva y se procesa dentro del ColumnTransformer aplicando un OrdinalEncoder en el caso de los modelos de árboles. En la regresión se integra mediante WoE.

4.3. Análisis multivariante

Se ha utilizado la correlación de Spearman para medir la asociación entre variables e identificar problemas de colinealidad. Su elección se justifica por medir la asociación monótona, más robusta que Pearson en distribuciones asimétricas y con outliers, ambos presentes en los datos de crédito.




Gráfico 5. Matriz de correlación de Spearman

La correlación es elevada entre el saldo hipotecario pendiente (MORTDUE) y el valor del inmueble (VALUE), con un coeficiente $\rho = 0,86$. Es coherente desde el punto de vista económico, pero puede generar colinealidad y comprometer la capacidad explicativa del modelo. Para identificarla se fija un umbral de $|\rho| > 0,7$; el resto de variables no lo superan y, por tanto, no constituyen un riesgo de colinealidad.

Estos resultados desaconsejan incluir simultáneamente MORTDUE y VALUE. Como alternativa, se plantea su transformación en un ratio financiero, *Combined Loan-to-Value* (CLTV), al estar tanto el préstamo como el saldo hipotecario sujetos a la misma garantía hipotecaria. Esta transformación se aborda en el apartado 4.4.

Atendiendo a la correlación con la variable objetivo, las variables de comportamiento crediticio encabezan la asociación con BAD, en sentido positivo DELINQ y DEROG, y en sentido protector CLAGE, resultado consistente con los análisis anteriores. Las correlaciones individuales son moderadas en todos los casos, lo que confirma que ninguna variable por sí sola es suficiente para predecir el impago. Debe tenerse en cuenta, además, que al ser BAD una variable binaria y varias predictoras de conteo, la correlación de Spearman con BAD se interpreta como indicador orientativo de asociación monótona, no como medida exacta de poder predictivo.

4.4.Construcción de CLTV

Como se explicó en el apartado anterior, la correlación entre MORTDUE y VALUE es 0,86. Esto genera colinealidad: la matriz de covarianzas de ambas se vuelve casi singular y sus coeficientes estimados, inestables. Para resolverlo se aprovecha el vínculo entre ambas mediante el ratio CLTV, que representa la proporción del valor del inmueble comprometida por deuda y es un indicador estándar en la industria hipotecaria para medir el apalancamiento del prestatario.

$$CLTV = \frac{LOAN + MORTDUE}{VALUE}$$

Las estadísticas revelan valores extremos no plausibles en un entorno real: 25 registros con CLTV superior a 5 y un máximo de 9,49. Valores en el rango 5 a 9,5 no tienen interpretación económica válida en préstamos con garantía hipotecaria (HMEQ) y apuntan a errores de captura en VALUE, cuyos mínimos (8.000 USD) resultan inverosímiles para inmuebles hipotecados en economías desarrolladas. La inspección de estos 25 registros confirma que todos, salvo uno, corresponden a clientes sin default (BAD = 0), lo que refuerza la hipótesis de error de datos: no hay evidencia de que representen perfiles de riesgo extremo con valor predictivo.




Gráfico 6. Boxplot CLTV

El boxplot segmentado por BAD confirma visualmente el diagnóstico. En ambos grupos la distribución se concentra por debajo de 2,55, y los valores anómalos aparecen como puntos aislados, con un gap nítido entre 2,55 y 5,0 en el que no existe ninguna observación. Este vacío es de difícil interpretación económica y constituye, con alta probabilidad, un error de captura.

Se descarta la winsorización estadística por percentil (p99, p99,5) en favor de un umbral económico: cap en CLTV = 2,55. Este umbral se justifica por tres razones:

- Respaldo empírico: el boxplot muestra un gap estructural entre los 25 registros anómalos ($CLTV > 5$) y el resto ($CLTV \leq 2,55$). La ausencia de valores en el intervalo (2,55, 5,0) confirma que el corte no es arbitrario, sino que refleja una discontinuidad real en los datos.
- Interpretación financiera: un CLTV de 2,55 implica una deuda total equivalente al 255 % del valor del inmueble, situación de negative equity severa pero no imposible en escenarios de estrés (depreciación del activo o reestructuración de deuda).
- Alineación regulatoria: las guías de la EBA (*European Banking Authority*) sobre validación de modelos IRB exigen documentar y justificar el tratamiento de datos anómalos. Un umbral económico es más transparente y auditable que uno puramente estadístico, cuya elección (p99 frente a p99,5) podría considerarse arbitraria.

Tras aplicar el cap, el heatmap de correlación con los datos preprocesados confirma que ninguna variable supera el umbral $|p| > 0,7$. La variable CLTV sustituye a MORTDUE y VALUE en todos los modelos del Capítulo 5, tratada exclusivamente dentro del pipeline mediante un transformador personalizado (CLTVTransformer).

Su correlación con la variable objetivo es prácticamente nula y ligeramente negativa ($\rho = -0,05$), lo que indica que la relación entre apalancamiento e impago no es monótona. Esta característica se retoma en el Capítulo 5, al definir las restricciones de monotonía de los modelos benchmark.




Gráfico 7. Matriz de correlación de Spearman + CLTV

4.5.Síntesis de EDA

El análisis exploratorio ha permitido caracterizar la estructura del dataset HMEQ y fijar las decisiones de preprocesamiento que condicionan la fase de modelización. La variable objetivo presenta un desbalance en torno al 20 %, lo que orienta la evaluación hacia métricas de discriminación y calibración. El análisis univariante ha evidenciado distribuciones asimétricas y colas pesadas, con valores extremos que concentran la señal de riesgo, por lo que se conservan. El estudio de la calidad del dato ha confirmado mecanismos de ausencia no aleatorios, cuyo tratamiento preserva la información del patrón de missing. En el plano multivariante, la colinealidad detectada entre MORTDUE y VALUE ($p = 0,86$) se resuelve mediante la construcción del ratio CLTV, que las sustituye en los modelos.

Sobre esta base depurada se construyen, en el Capítulo 5, el modelo principal (Regresión Logística con WoE) y los dos modelos benchmark (LightGBM y XGBoost), evaluados mediante métricas de discriminación, calibración y estabilidad poblacional.

5. Modelización

El esquema a seguir, ampliamente adoptado en la modelización de riesgo de crédito (Baesens et al., 2016), enfrenta un modelo principal a dos modelos benchmark. El modelo principal es el que mejor responde a las exigencias del contexto regulatorio bancario: *Baesens et al.* señala que un buen scorecard no se evalúa solo por su precisión estadística, sino también por su interpretabilidad y su cumplimiento regulatorio, entre otras dimensiones. Bajo este criterio, un modelo white box como la regresión logística con WoE, cuya lógica es directamente comprensible y auditable, resulta preferible a un modelo black box, aun cuando este pueda ofrecer mayor capacidad predictiva. Los

benchmark, por su parte, permiten medir el coste en discriminación que supone optar por ese modelo regulatoriamente más defendible. Se desarrollan tres modelos:

- Modelo principal: Regresión Logística combinada con la transformación Weight of Evidence (WoE). Esta combinación constituye el estándar histórico del credit scoring bancario por su interpretabilidad nativa, su trazabilidad y su alineación con los requerimientos regulatorios bajo el enfoque IRB y la norma IFRS 9.
- Modelo benchmark 1: LightGBM, técnica de gradient boosting con histogramas que ofrece elevada eficiencia computacional y captura nativa de no linealidades.
- Modelo benchmark 2: XGBoost, técnica de gradient boosting secuencial con regularización L1 y L2, ampliamente referenciada en la literatura reciente sobre credit scoring (Bahnsen et al., 2014; Thomas et al., 2002).

Los tres modelos comparten la misma partición train/test (70/30 estratificada por BAD, random_state=123), las mismas variables explicativas tras el preprocesamiento descrito y el mismo conjunto de prueba, lo que garantiza la comparabilidad de los resultados en el Capítulo 6.

No obstante, cada modelo incorpora un pipeline de preprocesamiento propio: el principal añade binning óptimo y transformación WoE, mientras que los benchmark emplean un pipeline de scikit-learn con imputación de valores faltantes y encoding ordinal para las variables categóricas. La justificación de cada enfoque se detalla en los apartados siguientes.

Por último, cabe indicar que antes de fijar estos tres modelos se valoraron otras familias y se descartaron por motivos concretos. El random forest se dejó fuera porque en problemas tabulares como este el gradient boosting suele extraer algo más de señal. Las redes neuronales se descartaron por el tamaño de la muestra, que con cerca de seis mil registros no da margen para que aporten ventaja, y por una opacidad todavía mayor que la del boosting, lo contrario de la transparencia que el contexto exige. También se analizó la máquina de vector soporte (SVM), descartada porque no entrega probabilidades calibradas de forma nativa, y aquí la PD tiene que ser una probabilidad creíble y no solo una frontera de decisión.

El desarrollo completo está disponible en los notebooks del repositorio (Anexo A).

5.1. Modelo principal: Regresión Logística + WoE y binning óptimo

Se ha atendido a la metodología tradicional de construcción de scorecards de riesgo de crédito, ampliamente utilizada en banca para la estimación de la PD en modelos de Application Scoring.

El enfoque adoptado para el modelo principal no es arbitrario: es el estándar bancario, donde cada paso refuerza la explicabilidad que exige el regulador. Este enfoque pasa por:

- La discretización supervisada de variables
- La transformación mediante el método *Weight of Evidence* (WoE) para el conjunto de entrenamiento,
- La medición del poder predictivo a través de *Information Value* (IV).
- El modelo de regresión logística GLM.

5.1.1. La discretización supervisada de variables

La discretización se ha realizado con la librería *optbinning*, que tiene en cuenta en primer lugar la variable objetivo para realizar los cortes (binning supervisado) y, en segundo lugar, construye los tramos de manera óptima maximizando el Information Value. Los tramos están sujetos a restricciones: tamaño mínimo de bin (típicamente un 5 % de la muestra), monotonidad del WoE, número máximo de tramos y significancia estadística.

Esta discretización permite:

- Capturar no linealidades: cada tramo estima su propio nivel de riesgo, sin imponer una relación lineal entre la variable y el impago.
- Tratar los valores ausentes como un tramo propio, sin imputarlos, lo que es relevante para la trazabilidad bancaria. Esta decisión es especialmente significativa para DEBTINC, cuyo mecanismo de ausencia es MNAR (véase apartado 3.2).
- Robustez ante outliers: los valores extremos caen en los tramos de los bordes y no distorsionan el modelo. Esta propiedad se validó empíricamente en el preprocesamiento del CLTV (apartado 4.4): el cap aplicado en 2,55 no alteró las métricas del modelo, lo que confirma que el binning WoE ya neutralizaba estos casos por construcción.

5.1.2. Transformación mediante el Weight of Evidence (WoE)

El WoE de un tramo es el logaritmo natural del cociente entre la proporción de buenos pagadores (sobre el total de buenos) y la proporción de malos pagadores (sobre el total de malos) que contiene ese tramo.

$$WoE_i = \ln\left(\frac{\% Good_i}{\% Bad_i}\right)$$

Este valor es el que se introduce en la regresión logística, por su capacidad de convertir la relación entre cada tramo de las variables explicativas y la log-odds del target en una relación lineal. Es una propiedad clave, ya que la regresión logística asume que cada variable se relaciona linealmente con el logaritmo del cociente de probabilidades (log-odds) de la variable objetivo. La transformación WoE garantiza esa linealidad por construcción, lo que permite ajustar un modelo logístico sobre variables que originalmente presentaban relaciones no lineales con el target.

En cuanto a interpretabilidad, el signo y la magnitud del WoE permiten una lectura directa del nivel de riesgo de cada tramo respecto a la media de la muestra:

Signo del WoE	Interpretación
WoE > 0	El tramo concentra una proporción de buenos pagadores superior a la media de la muestra. Indica menor riesgo relativo .
WoE < 0	El tramo concentra una proporción de malos pagadores superior a la media de la muestra. Indica mayor riesgo relativo .
WoE ≈ 0	El tramo es neutro respecto al riesgo medio de la muestra.

Tabla 7. Interpretabilidad de WoE

5.1.3. El poder predictivo a través de Information Value (IV).

Una vez calculado el WoE de cada tramo, se evalúa el poder discriminante global de la variable mediante el Information Value (IV), que mide la divergencia entre la distribución

de buenos y la de malos pagadores a lo largo de los tramos: cuanto mayor es la separación entre ambas, mayor es el poder predictivo de la variable.

$$IV = \sum_{i=1}^n (\% Good_i - \% Bad_i) \times WoE_i$$

Los umbrales de Siddiqi (2017) sirven de referencia orientativa para clasificar el poder predictivo a partir del IV (Tabla 11).

Information Value (IV)	Poder predictivo
IV < 0,02	No predictivo — descartar variable
0,02 ≤ IV < 0,10	Débil
0,10 ≤ IV < 0,30	Medio
0,30 ≤ IV < 0,50	Fuerte
IV ≥ 0,50	Sospechoso: posible <i>data leakage</i>

Fuente: adaptado de Siddiqi (2017), *Intelligent Credit Scoring*.

Tabla 8. Interpretabilidad de Information Value

Las variables con IV muy elevado deben revisarse para descartar fugas de información del target (*data leakage*), mientras que las que quedan ligeramente por debajo del umbral mínimo pueden mantenerse si aportan racionalidad económica.

El cálculo se ha realizado sobre las once variables explicativas resultantes del preprocesamiento del Capítulo 4 (ya con CLTV en lugar de MORTDUE y VALUE), mediante dos métodos de binning cuya comparación se recoge en la Tabla 11.

- Un IV preliminar con `scorecardpy.iv()` (binning automático no supervisado)
- IV definitivo tras aplicar `OptimalBinning`, con restricciones de monotonicidad

variable	IV_continuo	IV_optbinning	diferencia
DEBTINC	0.04	1.95	1.91
DELINQ	0.66	0.59	-0.07
DEROG	0.45	0.36	-0.08
CLAGE	0.07	0.24	0.17
LOAN	0.86	0.21	-0.64
CLTV	0.04	0.18	0.15
NINQ	0.17	0.16	-0.01
JOB	0.14	0.13	-0.01
CLNO	0.26	0.10	-0.16
YOJ	0.36	0.09	-0.27
REASON	0.00	0.00	-0.00

Tabla 9. Information Value

La comparación pone de manifiesto la sensibilidad del IV a la granularidad del binning. LOAN y DEBTINC presentan las desviaciones más relevantes y merecen un análisis específico.

- DEBTINC muestra el comportamiento opuesto: su IV se dispara con el *OptimalBinning*, situándose por encima del umbral de sospecha. El análisis por tramo revela que el *bin* de valores ausentes aporta por sí solo el 55 % del IV de la variable, con una tasa de evento del 62,96 % frente al 19,94 % de entrenamiento.

Este patrón consolida el estudio MNAR hecho en el capítulo 3.2. aquí se confirma que la ausencia del ratio deuda-ingresos tiene un alto poder de predicción. Por tanto, el IV elevado no es síntoma de data *leakage*, sino expresión de una propiedad relevante del *dataset*; la transformación WoE permite preservar esta información al tratar los valores ausentes como una categoría adicional en lugar de imputarlos.

- LOAN cae con fuerza del *binning* continuo al *OptimalBinning*. El continuo la trocea en exceso, inflando el IV con *bins* de tasas extremas. El óptimo lo corrige y refleja la señal real: el riesgo se concentra en los préstamos inferiores a 6.050 USD (48 % de impago frente al 19,94 % poblacional), con relación no monótona en el resto del rango, por lo que se aplica *monotonic_trend = None*.
- DELINQ también supera el umbral de sospecha. En este caso, el IV elevado responde a su naturaleza de variable de comportamiento crediticio (número de líneas en mora), un predictor directo y legítimo del impago, y no a una fuga de información, por lo que se mantiene en el modelo.
- REASON tras el análisis en el capítulo 4.2.3 donde no se aprecia poder de separación, su IV es muy bajo por lo que no será incluido en el modelo.

5.1.4. Modelo de regresión logística GLM.

En síntesis, el modelo principal incorpora **diez variables** tras la transformación WoE, derivadas del binning óptimo: LOAN, DELINQ, DEROG, YOJ, CLNO, NINQ, JOB, CLAGE, DEBTINC y CLTV.

Sobre ellas se ajusta un modelo de regresión logística (GLM binomial con enlace logit, estimado por IRLS) sobre el conjunto de entrenamiento, mediante la librería statsmodels, que proporciona inferencia estadística completa sobre los coeficientes.

Generalized Linear Model Regression Results						
=====						
Dep. Variable:	BAD	No. Observations:	4172			
Model:	GLM	Df Residuals:	4161			
Model Family:	Binomial	Df Model:	10			
Link Function:	logit	Scale:	1.0000			
Method:	IRLS	Log-Likelihood:	-1269.8			
Date:	ju., 11 jun. 2026	Deviance:	2539.7			
Time:	21:32:58	Pearson chi2:	4.19e+03			
No. Iterations:	6	Pseudo R-squ. (CS):	0.3233			
Covariance Type:	nonrobust					
=====						
	coef	std err	z	P> z	[0.025	0.975]

Intercept	-0.3909	0.064	-6.078	0.000	-0.517	-0.265
woe_LOAN	-0.6884	0.106	-6.480	0.000	-0.897	-0.480
woe_DELIHQ	-0.9439	0.068	-13.978	0.000	-1.076	-0.812
woe_DEROG	-0.7409	0.087	-8.524	0.000	-0.911	-0.571
woe_YOJ	-0.6335	0.212	-2.981	0.003	-1.050	-0.217
woe_CLNO	-1.0607	0.164	-6.486	0.000	-1.381	-0.740
woe_NINQ	-0.4221	0.132	-3.188	0.001	-0.682	-0.163
woe_JOB	-0.8081	0.155	-5.218	0.000	-1.112	-0.505
woe_CLAGE	-1.1022	0.109	-10.077	0.000	-1.317	-0.888
woe_DEBTINC	-1.5774	0.069	-22.996	0.000	-1.712	-1.443
woe_CLTV	-0.6738	0.137	-4.932	0.000	-0.942	-0.406

Tabla 10. Resultados GLM

Todos los coeficientes presentan signo negativo, coherente con la construcción del WoE: un tramo con WoE positivo (menor riesgo relativo) reduce la log-odds de impago, mientras que un tramo con WoE negativo (mayor riesgo) la incrementa. Todos son estadísticamente significativos al 1 % ($p\text{-valor} < 0,01$), lo que confirma la relevancia de cada variable.

El modelo entrenado, junto con los objetos de binning, se serializa mediante `joblib` para su reutilización en el capítulo de validación. Los archivos `woe_logreg_model.pkl`, `woe_bins.pkl`, `woe_train_set.pkl` y `woe_test_set.pkl` quedan disponibles en el directorio `models/` del repositorio (Anexo A).

5.2. Benchmark 1: LightGBM

El primer modelo benchmark es LightGBM. El objetivo no es solo medir su capacidad predictiva, sino contrastar si la ganancia en discriminación (AUC, Gini, KS) frente al modelo principal compensa la pérdida de interpretabilidad nativa que exige el regulador, cuestión que se retoma en la comparación del Capítulo 6.

5.2.1. Justificación del modelo

La elección de *gradient boosting* como benchmark responde a tres ventajas frente al modelo principal: su robustez ante outliers y variables asimétricas (predominantes en

HMEQ), su gestión nativa de los valores ausentes, sin imputación, y su capacidad de capturar interacciones entre variables, que el WoE univariado no modela.

Dentro de esta familia, LightGBM se elige como primer benchmark por dos características propias:

La elección de *gradient boosting* como técnica benchmark se justifica por las siguientes razones:

- Construcción basada en histogramas: discretiza las variables continuas en bins y evalúa los cortes sobre esos *bins* agregados, lo que reduce notablemente el coste computacional sin apenas pérdida de capacidad predictiva.
- Crecimiento *leaf-wise*: en cada iteración expande la hoja que más reduce la pérdida (frente al crecimiento nivel a nivel), lo que mejora la eficiencia y capta relaciones complejas. Como contrapartida, eleva el riesgo de sobreajuste, controlado mediante `num_leaves` y `min_child_samples` en la búsqueda de hiperparámetros.

5.2.2. Pipeline de preprocesamiento

El preprocesamiento se implementa mediante un ColumnTransformer con dos ramas:

- Variables numéricas: se aplica únicamente la clase personalizada CLTVTransformer, que construye la variable CLTV (con cap económico en 2.55) y elimina las variables MORTDUE y VALUE. No se aplica imputación sobre las variables numéricas: LightGBM gestiona los valores ausentes de forma nativa, aprendiendo durante el entrenamiento la dirección óptima del *split* que minimiza la función de pérdida en cada nodo.
- Variables categóricas (REASON y JOB): se aplica una secuencia de dos pasos. En primer lugar, un *SimpleImputer* con estrategia *constant* asigna la etiqueta "Missing", tratando la ausencia como una categoría adicional informativa. En segundo lugar, un *OrdinalEncoder* convierte las categorías a enteros para su consumo por el algoritmo. La elección de *OrdinalEncoder* frente a *OneHotEncoder* se justifica por el tratamiento que los algoritmos basados en árboles dan al *encoding*: los árboles de decisión encuentran particiones óptimas independientemente del orden numérico asignado a cada categoría, por lo que la expansión *one-hot* solo introduce dispersión innecesaria del espacio de *features* y aumenta el coste computacional sin aportar capacidad predictiva.

La clase CLTVTransformer se ha extraído al módulo compartido `src/transformers.py`, evitando duplicar código entre notebooks y permitiendo cargar los pipelines serializados sin redefinirla, patrón habitual en entornos bancarios de producción.

El ColumnTransformer y el LGBMClassifier se encapsulan en un Pipeline único de scikit-learn. Esto no es solo organizativo: garantiza que, durante la validación cruzada de la búsqueda de hiperparámetros, el preprocesamiento se reajuste de forma independiente en cada fold, evitando fugas de información hacia el entrenamiento, requisito habitual en la documentación de modelos bajo IRB. A diferencia del modelo principal, este pipeline no incorpora la transformación WoE.




Tabla 11. Pipeline LightGBM

Arriba se observa el pipeline completo junto con los valores por defecto del LGBMClassifier, que sirven de punto de partida para la búsqueda de hiperparámetros del apartado siguiente.

5.2.3. Búsqueda de hiperparámetros

La optimización se realiza mediante GridSearchCV con validación cruzada estratificada de 5 folds sobre el conjunto de entrenamiento. El uso de StratifiedKFold garantiza que la proporción de impagos (19,94 %) se mantenga estable en cada fold, requisito fundamental en datasets desbalanceados.

Como métrica de optimización se selecciona el AUC-ROC, por tres motivos:

- Es robusto frente al desbalance de clases, ya que evalúa la capacidad discriminante del modelo a lo largo de todos los puntos de corte posibles sin asumir un umbral de decisión específico
- Independiente del umbral: la selección del modelo se basa en su capacidad de ordenar a los clientes por riesgo, no en un punto de corte concreto que se aborda más adelante con cost-sensitive
- Coherencia con el criterio de comparación: el AUC (y su transformación, Gini) es la métrica de discriminación con la que se comparan los tres modelos en el Capítulo 6.

La búsqueda se estructura en tres iteraciones, lo que permite aislar el efecto de cada hiperparámetro y, sobre todo, auditar la estabilidad del AUC train = 1 bajo distintos regímenes de regularización: tamaño del árbol, mínimo de observaciones por hoja y umbral de ganancia por split.

- Grid 1 (108 combinaciones). Búsqueda inicial sobre los cuatro hiperparámetros de mayor impacto en el equilibrio entre capacidad y regularización: `n_estimators`, `max_depth`, `learning_rate` y `min_child_samples`. El óptimo se localiza en los valores de máxima complejidad (`n_estimators=500`, `max_depth=7`) y mínima regularización (`min_child_samples=10`), con AUC de test de 0,9691.
- Grid 2 (324 combinaciones). Incorpora `num_leaves`, distintivo de LightGBM por su crecimiento leaf-wise. Su valor por defecto (31) puede quedarse corto con `max_depth=7` (que admite hasta 128 hojas) o excederse con `max_depth=3` (máximo 8). La búsqueda sobre [15, 31, 63] confirma `num_leaves=63` como óptimo, pero el AUC de test no varía (0,9691), por lo que la mejora no compensa el mayor coste computacional.
- Grid 3 (5 combinaciones). Partiendo del óptimo del Grid 2, se explora únicamente `min_split_gain`, que fija la ganancia mínima que debe aportar un split para ejecutarse. El objetivo es verificar la robustez del modelo ante un umbral de poda activo, a un coste muy bajo.

La búsqueda incremental sobre los Grids 2 y 3 no mejora el comportamiento fuera de muestra: el AUC de test se mantiene estable (0,9685–0,9691) y el Brier empeora ligeramente (de 0,0585 a 0,0614–0,0619). Por parsimonia, se toma la configuración del Grid 1 como referencia, sobre la que se aplicará la restricción de monotonía en el apartado siguiente.

Modelo	AUC train	AUC test	KS Test	Brier test	Log loss test	AUC val	dif train/val	dif val/test
Principal (Grid 1)	1.0000	0.9691	0.8238	0.0585	0.2369	0.9496	0.0504	-0.0195
Principal (Grid 2)	1.0000	0.9691	0.8258	0.0614	0.2875	0.9503	0.0497	-0.0188
Principal (Grid 3)	1.0000	0.9685	0.8378	0.0619	0.2739	0.9505	0.0495	-0.0180

Tabla 12 – Métricas Grid Modelo principal.

El AUC de entrenamiento es 1, invariante en **los óptimos de las tres iteraciones**, mientras el de test oscila en un rango estrecho (0,9685–0,9691). Esta invariancia

descarta que el ajuste perfecto proceda de una regularización subóptima del algoritmo y apunta a una propiedad estructural del dataset HMEQ: la combinación de variables continuas de alta granularidad (DEBTINC, CLAGE, CLTV) con la profundidad de árbol seleccionada permite construir reglas que clasifican correctamente todo el entrenamiento. La generalización queda respaldada por el AUC de validación cruzada (0,9496), cercano al de test y ligeramente inferior, lo que indica que el modelo no se sobreajusta a los folds. El análisis del posible sobreajuste se desarrolla en los apartados siguientes.

5.2.3.1. Análisis del sobreajuste: descarte de data leakage

El AUC de entrenamiento igual a 1 obliga a plantearse si alguna variable predictora contiene, de forma indirecta, información de la variable objetivo (data leakage). Si así fuera, el ajuste perfecto sería un artefacto y no una característica del problema.

El análisis de correlación con BAD del Capítulo 4.3 ya descartó una dependencia directa entre las variables predictoras y el objetivo: la relación más fuerte es solo moderada entre DELINQ y BAD con $\rho = 0,33$, lejos de la correspondencia uno a uno que delataría una variable contaminada. Como verificación adicional, se evalúa el poder predictivo individual de cada variable.

Para ver el poder predictivo individual, se mide el AUC que alcanza cada variable empleada en solitario como score de riesgo: si una sola rozara un valor cercano a 1, sería el objetivo disfrazado.

Imputando los ausentes por la mediana, ninguna supera 0,66 (DELINQ). Enviando los ausentes a un extremo de riesgo, replicando el tratamiento nativo de LightGBM, DEBTINC asciende a 0,83 y el resto permanece por debajo de 0,63. En ningún caso una variable se aproxima a 1, lo que indica que el ajuste perfecto procede de la combinación de variables y no de una de ellas.

El peso de DEBTINC responde a su mecanismo MNAR, ya caracterizado en el Capítulo 3.2, y no a una fuga de información: que el ratio deuda-ingresos falte en la solicitud es un dato disponible en el momento de la decisión, no un resultado posterior del préstamo. La importancia de cada variable en el modelo se detalla más adelante, pero se adelanta que DEBTINC es la que más importancia tiene, tres veces superior a la segunda.

En conjunto, a pesar de tener un alto poder predictivo, los datos de las pruebas descartan el data leakage ya que ninguna variable encierra el objetivo, y el ajuste perfecto sobre entrenamiento se explica por la combinación de predictores junto con la señal MNAR de DEBTINC. El AUC train = 1 es, por tanto, una propiedad estructural del dataset HMEQ y no un artefacto del modelo.

5.2.3.2. Monotonía y métrica de optimización

Con el AUC de entrenamiento ya analizado, se introducen restricciones de monotonía para reforzar la explicabilidad del modelo. Un modelo de gradient boosting puede asignar a una misma variable direcciones de riesgo contradictorias según el tramo, lo que dificulta su lectura de negocio. Para alinearlos con la interpretabilidad del modelo principal (monótono por construcción del WoE), se imponen restricciones de monotonía (monotone_constraints), tomando las direcciones del binning supervisado del modelo principal. Su corrección se verifica por dos vías independientes: la correlación de Spearman con BAD (tendencia empírica) y los plots de SHAP.

Variable	ρ Spearman	Monotonía impuesta (optimal binning)	Tendencia empírica	Coherencia
LOAN	-0,1081	Libre	Descendente	Revisar
DELINQ	0,3342	Ascendente	Ascendente	OK
DEROG	0,2852	Ascendente	Ascendente	OK
YOJ	-0,0760	Descendente	Descendente	OK
CLNO	-0,0093	Libre	—	OK
NINQ	0,1508	Ascendente	Ascendente	OK
CLAGE	-0,1791	Descendente	Descendente	OK
DEBTINC	0,1464	Ascendente	Ascendente	OK
CLTV	-0,0528	Libre	Descendente	Revisar

Tabla 13. Comparación monotonía Optimal Binning y Correlación de Spearman

De las nueve variables, solo dos requieren revisión, LOAN y CLTV:

- **LOAN:** la correlación de Spearman es débil y negativa, pero el gráfico de WoE muestra una relación no monótona en zig-zag, con el mayor riesgo concentrado en los préstamos pequeños. Sobre esa forma, Spearman se aplana, de ahí su ρ débil. Se deja sin restricción.




Gráfico 9. Optimal Binning LOAN

- **CLTV:** $\rho \approx -0,05$, casi nulo y de signo contraintuitivo, ya que a mayor apalancamiento sobre el colateral no cabe esperar menor riesgo. No existe una relación monótona limpia, por lo que imponer una dirección no estaría respaldado por los datos. Se deja sin restricción.




Gráfico 10. Optimal Binning cltv

La verificación con SHAP confirma estas direcciones. En el gráfico, un valor alto (rojo) situado a la derecha indica mayor riesgo (relación ascendente) y, a la izquierda, menor riesgo (descendente). DEBTINC, DELINQ, DEROG y NINQ se comportan como ascendentes; CLAGE y YOJ, como descendentes; y CLNO, LOAN y CLTV no muestran un patrón claro, coherente con dejarlas sin restricción.




Gráfico 11. SHAP

En conjunto, Spearman y SHAP confirman que las direcciones derivadas del WoE son correctas y coinciden con las que LightGBM aprende de forma espontánea. La imposición de monotonía no busca corregir el sobreajuste, cuyo efecto es marginal, sino dotar al modelo de un sentido de negocio coherente, requisito de explicabilidad en riesgo de crédito.

Adicionalmente, se replica la búsqueda sustituyendo el AUC por el log loss como métrica de optimización. Mientras el AUC mide solo discriminación, el log loss incorpora también la calibración, lo que permite contrastar si la elección de métrica altera el modelo resultante. La comparación de las cuatro variantes (con y sin monotonía, optimizadas por AUC o por log loss) se desarrolla en el apartado siguiente.

5.2.4. Comparación: Modelos de LightGBM con y sin monotonía y con optimización (AUC vs Log Loss)

Para evaluar el efecto conjunto de la monotonía y de la métrica de optimización, se comparan cuatro variantes del modelo, cruzando monotonía (con/sin) y métrica (AUC/log loss).

Modelo	AUC train	AUC test	Gini train	Gini test	KS Train	KS Test	Brier train	Brier test	Log loss train	Log loss test
Principal (AUC, sin mono)	1.0000	0.9691	1.0000	0.9382	1.0000	0.8238	0.0000	0.0585	0.0011	0.2369
AUC + monotonía	1.0000	0.9547	1.0000	0.9094	1.0000	0.7831	0.0007	0.0611	0.0099	0.2402
log loss, sin mono	0.9977	0.9587	0.9953	0.9175	0.9469	0.7859	0.0210	0.0609	0.0899	0.2015
log loss + monotonía	0.9797	0.9497	0.9594	0.8993	0.8485	0.7580	0.0419	0.0638	0.1513	0.2156

Tabla 14 – Métricas Modelo principal.

La lectura de la tabla arroja cuatro observaciones:

- El AUC de entrenamiento se mantiene en uno tanto en el modelo sin restringir como en el de AUC con monotonía. Imponer la restricción no rompe el ajuste perfecto; solo las variantes optimizadas por log loss, que recorren la rejilla con otra métrica, quedan algo por debajo. Que el ajuste perfecto persista incluso bajo monotonía refuerza que es una propiedad estructural del dataset y no un sobreajuste que la regularización pueda corregir.
- En test, el mejor AUC corresponde al modelo sin monotonía. Cualquier restricción lo rebaja, aunque por un margen pequeño.
- La calibración se mueve en la misma dirección. Tanto el Brier como el log loss empeoran ligeramente al imponer monotonía, pero las diferencias son reducidas en todos los casos.
- Cambiar la métrica a log loss no aporta una ventaja clara: mejora su propio log loss, pero no la discriminación, y empeora algo el Brier.

En términos estadísticos, el modelo sin monotonía sería el mejor. Sin embargo, la elección del benchmark no es solo a las métricas. En riesgo de crédito, la interpretabilidad y el sentido de negocio son requisitos relevantes además de la discriminación por lo tanto un modelo cuyas variables no respetan una dirección de riesgo coherente resulta difícil de justificar ante un área de negocio o un validador. Por ello, asumiendo ese coste marginal, se adopta como benchmark el modelo con monotonía optimizado por AUC, que entre las variantes monótonas ofrece la mejor discriminación y el mejor Brier, por delante de la versión optimizada con log loss.

5.2.5. Importancia de las variables

LightGBM proporciona dos métricas nativas para evaluar la contribución de cada variable al modelo: el número de *splits* (frecuencia con la que el algoritmo utiliza la

variable para particionar) y la ganancia acumulada (reducción total de la función de pérdida que aporta la variable).

Por ganancia acumulada:




Gráfico 12. Importancia por variables

Por ganancia, DEBTINC es la variable más informativa pese a ser solo la quinta en importancia por número de splits. Son pocas particiones, pero muy informativas, coherente con su mecanismo MNAR ya descrito. Le siguen CLAGE y CLTV, que son además las más frecuentes por splits gracias a su granularidad continua.

DELINQ ilustra un contraste útil. Es séptima por ganancia pese a tener el segundo IV más alto (0,59). El IV mide su poder en solitario; la ganancia, su aporte condicionado al resto. Como DEBTINC y CLAGE ya capturan buena parte de la señal, el valor marginal de DELINQ es menor.

5.2.6. Persistencia del modelo

El pipeline completo (ColumnTransformer + LGBMClassifier) se serializa mediante joblib y se almacena en el directorio models/ del repositorio. Guardar el pipeline completo, y no solo el clasificador, garantiza la reproducibilidad del preprocesamiento (construcción de CLTV, imputación de categóricas y encoding ordinal) durante la inferencia sobre nuevas observaciones. El archivo resultante (lgbm_pipeline.pkl) se reutiliza en el notebook de comparación sin reentrenamiento

5.3. Benchmark 2: XGBoost

5.3.1. Particularidades de XGBoost

A diferencia de LightGBM, XGBoost emplea una estrategia de crecimiento level-wise: el árbol se expande nivel a nivel manteniendo una estructura balanceada, y todas las hojas de un mismo nivel se evalúan antes de pasar al siguiente. El resultado son árboles más simétricos, pero potencialmente menos profundos en las regiones de mayor señal predictiva.

XGBoost incorpora regularización L1 (reg_alpha) y L2 (reg_lambda) sobre los pesos de las hojas, una penalización que actúa sobre la magnitud del valor asignado a cada hoja terminal, en línea con los esquemas clásicos de regularización de los modelos lineales.

LightGBM dispone de los mismos parámetros, de modo que la diferencia no está en su disponibilidad, sino en la configuración por defecto: XGBoost aplica L2 de manera predeterminada (`reg_lambda=1`), mientras que en LightGBM la regularización permanece desactivada por defecto.

En cuanto a los valores ausentes, XGBoost los gestiona de forma nativa: durante el entrenamiento aprende en cada split un default direction que envía las observaciones con NaN al branch que minimiza la pérdida. En este TFM, el pipeline de XGBoost aprovecha esa capacidad y deja pasar los NaN sin imputación previa, igual que el de LightGBM. Así, ambos modelos reciben exactamente el mismo tratamiento de los ausentes, y en particular la señal MNAR de DEBTINC se conserva en los dos.

La comparación queda limitada a la diferencia que de verdad interesa, la estrategia de crecimiento del árbol.

5.3.2. Pipeline de preprocesamiento

El pipeline de XGBoost replica la estructura del construido para LightGBM (apartado 5.2): un ColumnTransformer con la misma rama categórica (imputación con la categoría "Missing" y codificación ordinal) y la clase CLTVTransformer importada del módulo compartido `src/transformers.py`, todo encapsulado junto al XGBClassifier en un único Pipeline de scikit-learn.

La rama numérica también es idéntica a la de LightGBM: solo aplica el CLTVTransformer y deja pasar los valores ausentes sin imputar, de modo que XGBoost los gestiona de forma nativa. Concluyendo ambos modelos gestionarán de forma nativa los missing values teniendo en cuenta la señal MNAR de la variable DEBTINC

5.3.3. Búsqueda de hiperparámetros

La calibración del modelo XGBoost se ha realizado llevando a cabo tres iteraciones de GridSearchCV sobre validación cruzada estratificada de 5 *folds* y *scoring* AUC-ROC.

- El primer grid son 108 combinaciones que exploran los cuatro hiperparámetros que gobiernan el equilibrio entre capacidad y regularización:
 - `n_estimators` [100, 300, 500]
 - `max_depth` [3, 5, 7]
 - `learning_rate` [0.01, 0.05, 0.1]
 - `min_child_weight` [1, 5, 10, 20].

Este último es el equivalente funcional de `min_child_samples` en LightGBM, con la diferencia de que actúa sobre la suma de los hessianos de las observaciones de la hoja y no sobre su recuento. El óptimo se localiza en los valores de mayor complejidad y menor regularización (500 / 7 / 0,1 / 1), con un AUC sobre test de 0,9619.

- La segunda iteración son 72 combinaciones donde no se amplía el espacio de búsqueda, lo refina. Se eliminan los valores más bajos que el Grid 1 ya había descartado, con el fin de reducir el coste de cómputo, y sobre ese entorno más

estrecho se incorpora gamma [0, 0,1, 0,5]. Este hiperparámetro fija la ganancia mínima que un split debe aportar a la función de pérdida para que el árbol lo ejecute, y es el equivalente conceptual de min_split_gain en LightGBM. La búsqueda devuelve gamma=0 como óptimo, de modo que el Grid 2 y el 1 arrojan métricas idénticas sobre test (AUC 0,9619). De aquí se concluye que penalizar la ganancia mínima de los splits no aporta generalización adicional en este dataset.

- La tercera iteración son 108 combinaciones que retoma el espacio amplio del primer Grid y añade la restricción monotone_constraints. El objetivo en este caso no es mejorar la discriminación, sino dotar al benchmark de la misma explicabilidad que el modelo principal WoE más Regresión Logística, imponiendo a cada variable la dirección monótona esperada frente a la probabilidad de impago. La monotonía tiene un coste marginal: el AUC sobre test baja de 0,9619 a 0,9552 y el KS de 0,8258 a 0,7768, mientras que el Brier mejora ligeramente, de 0,0619 a 0,0592. El modelo del Grid 3 es el que se adopta como benchmark final, por explicabilidad y por paridad con el tratamiento aplicado a LightGBM, asumiendo esa pérdida moderada de capacidad de discriminación.

Modelo	AUC train	AUC test	KS Train	KS Test	Brier train	Brier test	AUC val	dif train/val	dif val/test
Principal (Grid 1)	1.0000	0.9619	1.0000	0.8258	0.0005	0.0619	0.9409	0.0591	-0.0210
Principal (Grid 2)	1.0000	0.9619	1.0000	0.8258	0.0005	0.0619	0.9409	0.0591	-0.0210
Principal (Grid 3)	0.9974	0.9552	0.9502	0.7768	0.0196	0.0592	0.9341	0.0632	-0.0210

Tabla 15 – Métricas Grid Modelo principal.

5.3.4. Resultados y comparativa con LightGBM

El modelo XGBoost que se adopta como benchmark final es el tercer grid, con restricción de monotonía, bajo el mismo criterio de explicabilidad aplicado a LightGBM.

Métrica	LightGBM (monótono)	XGBoost (monótono)
AUC train	1,0000	0,9974
AUC val (CV)	0,9310	0,9341
AUC test	0,9547	0,9552
KS test	0,7831	0,7768
Brier test	0,0611	0,0592

Tabla 13. Comparaciones métricas LightGBM y XGBoost

Lo primero que destaca es que el AUC sobre entrenamiento vuelve a situarse en el entorno de 1,0000 en los dos algoritmos. Esto repite lo ya observado sin restricciones y refuerza la lectura de que el ajuste perfecto sobre train es una propiedad del dataset HMEQ e influenciado por los valores ausentes de DEBTINC.

Sobre test los dos benchmarks quedan prácticamente igualados, 0,9547 en LightGBM frente a 0,9552 en XGBoost. La diferencia cae dentro del ruido y no se puede confirmar cual discrimina mejor. Lo mismo ocurre con la validación cruzada. La calibración tampoco separa a los modelos: el Brier de XGBoost es algo mejor y el KS de LightGBM algo más alto.

El balance es un empate a efectos prácticos entre ambos métodos de boosting aunque ambos por encima en capacidad de discriminación sobre el modelo principal WoE y Regresión Logística en capacidad de discriminación.

Conviene precisar que la comparación es limpia en cuanto al tratamiento de ausentes: al haber retirado la imputación por mediana de la rama numérica, XGBoost recibe los valores ausentes de forma nativa igual que LightGBM, así que lo que se compara es la estrategia de crecimiento del árbol y no la gestión de los missing.

5.3.5. Importancia de las variables

Confirmando la jerarquía observada en LightGBM, la importancia por ganancia acumulada en XGBoost identifica a DEBTINC como la variable más informativa (13,77 de ganancia media por split). No obstante, las posiciones segunda y tercera difieren significativamente entre ambos algoritmos.

XGBoost sitúa en segundo y tercer lugar a DELINQ (4,43) y DEROG (3,27), que son justo las dos variables que, tras DEBTINC, encabezan el ranking de Information Value del modelo principal (IV de 0,59 y 0,36). XGBoost concentra así la ganancia en las variables de señal univariada más fuerte y reproduce el orden de los tres primeros puestos del análisis WoE.

LightGBM se comporta de otra manera. Sus posiciones segunda y tercera las ocupan CLTV (2.739) y CLNO (2.506), dos variables cuyo Information Value es bajo (0,18 y 0,10). No las eleva por su poder predictivo individual, sino porque su granularidad y las interacciones que habilitan le ofrecen muchos puntos de corte donde extraer ganancia. LightGBM reparte la importancia hacia variables de señal individual débil pero estructura aprovechable




Gráfico 13. Importancia por variables XGBoost

5.3.6. Persistencia del modelo

El modelo que se guarda es el benchmark final, esto es, el pipeline completo del Grid 3 con la restricción de monotonía ya incorporada. Se serializa con joblib en models/xgb_pipeline.pkl, siguiendo el mismo esquema empleado para LightGBM. El

objeto almacenado contiene tanto el ColumnTransformer de preprocesamiento como el clasificador XGBoost, de forma que al recargarlo en el notebook 05 se recupera la cadena entera y no hay que reconstruir ningún paso a mano.

Para que esa recarga funcione, la clase CLTVTransformer no se define dentro del notebook, se importa desde el módulo `src/transformers.py`. La razón es que joblib no guarda el código de las clases propias, solo una referencia a dónde vive cada una, así que el módulo compartido tiene que estar accesible en el momento de abrir el .pkl. Tener esa clase en un único lugar es lo que evita que el notebook de comparación se rompa al intentar deserializar el pipeline.

6. Validación y comparación

Con los tres modelos ya entrenados en el capítulo anterior, ahora se evalúa su comportamiento sobre el conjunto de test empleando las métricas y pruebas habituales en la validación de modelos de PD, que son las mismas que la regulación bancaria espera ver documentadas en un modelo IRB (Internal Ratings-Based).

La evaluación de las propiedades estadísticas del modelo se estructura en torno a las tres dimensiones clásicas de la validación:

- Discriminación o capacidad para separar incumplidores de no incumplidores. Las métricas que cubren esta dimensión son el área bajo la curva AUC-ROC, Gini y Kolmogorov-Smirnov.
- Calibración comprueba hasta qué punto las probabilidades predichas se corresponden con las frecuencias de impago observadas. Se examina tanto con el Brier Score como con la curva de calibración
- Estabilidad o robustez frente a variaciones poblacionales. Esta métrica es útil en fases post productivas especialmente ya que tiene en cuenta variaciones que se dan durante la vida del modelo en producción.

El refuerzo de este enfoque de evaluación viene determinado por ECB para modelos PD IRB disponible en la bibliografía.

La razón de uso de estas métricas son su capacidad para evaluar la ordenación del modelo a lo largo de todos los puntos de corte posible. No obstante, un scoring en producción opera en un solo punto de corte. Recall, precisión y F1 son métricas que evalúan al modelo exactamente en ese punto de corte, calculadas sobre la matriz de confusión.

		Matriz de confusión	
		Valor real	
Predicción del modelo		Impaga (BAD = 1)	Paga (BAD = 0)
	Impaga	Verdadero Positivo (TP) Mal pagador detectado	Falso Positivo (FP) Buen pagador rechazado Error tipo I
	Paga	Falso Negativo (FN) Mal pagador no detectado Error tipo II	Verdadero Negativo (TN) Buen pagador aprobado

Gráfico 14. Matriz de confusión

- El criterio cost-sensitive penaliza el falso negativo cuatro veces más que el falso positivo, lo que desplaza el umbral hacia un recall alto a costa de la precisión. Estas tres métricas son las que permiten evaluar ese intercambio y justificar el umbral elegido.
- El recall, o sensibilidad, mide qué proporción de los incumplidores reales identifica y deniega el modelo, $VP/(VP+FN)$. Es la métrica que más pesa en riesgo de crédito, porque el error caro es el falso negativo, aprobar a quien luego impaga.
- La precisión es la otra cara: de todas las operaciones que el modelo deniega, cuántas impagan de verdad, $VP/(VP+FP)$. Si es baja, se está rechazando a demasiados buenos pagadores, negocio que se deja de hacer.
- El F1, media armónica de ambas, solo sube cuando recall y precisión son altos a la vez. Resume su equilibrio en una cifra y es la métrica adecuada con clases desbalanceadas como esta, donde la exactitud engañaría: aprobar a todos acertaría el 80% sin separar a nadie.

6.1.Discriminación (AUC, Gini, KS) train vs test

La discriminación mide la capacidad del modelo para separar las observaciones de la clase positiva (incumplidores, $BAD=1$) de las negativas (no incumplidores, $BAD=0$). En validación bancaria se evalúa con tres métricas que se complementan:

- AUC-ROC: probabilidad de que un incumplidor reciba una PD superior a un no incumplidor seleccionado al azar. Es la métrica principal de ranking por su robustez frente al desbalance de clases.
- Gini: transformación lineal del AUC ($Gini = 2 \cdot AUC - 1$) acotado en el rango $[-1, 1]$. Ambos, AUC y Gini miden exactamente lo mismo.
- Kolmogorov-Smirnov (KS): máxima separación entre las distribuciones acumuladas de PD de incumplidores y no incumplidores. Mide la distancia óptima entre ambas poblaciones en un único punto.

Se inicia con los datos de entrenamiento

Modelo	AUC	Gini	KS	Brier Score
WoE + LogReg	0.8937	0.7873	0.6493	0.0924
LightGBM	1.0000	1.0000	1.0000	0.0007
XGBoost	0.9974	0.9947	0.9502	0.0196

Tabla 16 - Datos Train .

En entrenamiento, los dos benchmark alcanzan valores perfectos o casi perfectos. LightGBM llega a $AUC = Gini = KS = 1,0$, y XGBoost se queda a un paso, con un AUC de 0,9974, porque la restricción de monotonía le impide reproducir el ajuste perfecto que sí alcanza sin ella tal y como quedo auditado en el capítulo 5.

En cambio, el modelo principal se mueve en valores bastante más moderados con un AUC de 0,8937, un Gini de 0,7873 y un KS de 0,6493. La transformación WoE agrupa cada variable en unos pocos tramos antes del ajuste GLM, lo que le impide construir reglas tan finas como las que los árboles extraen de las variables continuas originales.

Sobre el conjunto de test, formado por 1.788 observaciones no vistas durante el entrenamiento, los tres modelos conservan una capacidad discriminante alta:

Modelo	AUC	Gini	KS	Brier Score
WoE + LogReg	0.8915	0.7830	0.6426	0.0957
LightGBM	0.9547	0.9094	0.7831	0.0611
XGBoost	0.9552	0.9103	0.7768	0.0592

Tabla 17 - Datos Test/Validación.

Los dos benchmark quedan prácticamente igualados y bastante por encima del modelo principal. XGBoost adelanta a LightGBM por un margen mínimo en AUC y Gini y la contrario con KS. Son distancias dentro del ruido, de modo que entre los dos boosting no hay diferencia.

En el WoE las métricas de train y test son casi calcadas, con una diferencia de apenas dos milésimas en AUC, 0,8937 frente a 0,8915, lo que descarta cualquier sobreajuste. En los dos benchmark la brecha train-test es mayor, alrededor de cuatro centésimas de AUC, pero no responde a un sobreajuste funcional: el AUC sobre test supera al de validación cruzada del capítulo 5.

En discriminación pura sobre test los dos benchmark superan al modelo principal por márgenes parecidos en las tres métricas. La diferencia más marcada está en el KS, donde la separación entre incumplidores y no incumplidores que consiguen los boosting es bastante mayor que la del WoE.

6.2. Curvas ROC comparadas

Cada punto de la curva corresponde a un umbral de corte distinto y traduce a una grafica lo que representa AUC.

En cada punto de corte se enfrenta TPR (incumplidores que el modelo deniega correctamente) contra FPR (buenos pagadores denegados por error). Recorriendo todos los umbrales posibles, se consigue una curva y la diagonal es el modelo que decidiría al azar, con AUC 0,5, (la mitad del área) y cuanto más se acerca una curva a la esquina superior izquierda, mejor separa a las dos poblaciones. El AUC de la tabla anterior es el área que queda bajo cada una de estas curvas.

Esta es la confirmación visual del apartado anterior donde las curvas de LightGBM y XGBoost aparecen casi superpuestas y por encima de la del modelo principal en todo el recorrido.

La diferencia se concentra además en la zona que más cuenta en la práctica. Un banco no trabaja en cualquier punto de la curva, sino en umbrales conservadores, con una tasa de falsos positivos baja, que es la parte izquierda del gráfico. Ahí es donde la separación entre los benchmark y el modelo principal se ensancha: para una misma proporción de buenos pagadores rechazados, los boosting detectan a bastantes más incumplidores. Esa misma brecha reaparece más adelante en las matrices de confusión, donde el WoE acumula más rechazos sobre clientes que no habrían impagado.




Gráfico 15. Curva ROC

6.3. Calibración (Curva de calibración y Brier Score)

La calibración evalúa si las probabilidades predichas se corresponden con las frecuencias de incumplimiento observadas.

La calibración determina la fiabilidad del valor absoluto de la PD, que alimenta directamente el cálculo de activos ponderados por riesgo (RWA) y de las provisiones por pérdida esperada por lo que es una dimensión crítica bajo Basel III e IFRS 9.

Se emplean dos herramientas complementarias:

- Brier Score mide el error cuadrático medio entre la PD predicha y el resultado observado (0 o 1); cuanto más bajo, mejor.
- La curva de calibración enfrenta, por deciles de PD, la probabilidad media predicha (eje X) con la tasa real de incumplimiento observada (eje Y); un modelo perfectamente calibrado se situaría sobre la diagonal.

En los modelos que pasan a la comparación, que son los monótonos, el ajuste a la diagonal es bueno en el modelo principal y en XGBoost, que la recorren casi sin separarse. LightGBM es el que más se aparta: queda por encima de la diagonal en los deciles de PD baja y por debajo en los de PD alta, con una curva más plana que la diagonal, propia de un modelo que estira sus predicciones hacia los extremos más de lo que la realidad respalda.




Gráfico 16. Calibración con monotonía

Disponer de las dos versiones de la curva, con y sin restricción de monotonía, permite aislar el efecto que esta tiene sobre la calibración de los árboles, y ese efecto no es el mismo en los dos. En XGBoost la monotonía ayuda. En LightGBM sucede lo contrario, o a lo sumo nada. Su curva, que sin restricción acompañaba a XGBoost cerca de la diagonal, se aleja al imponer la monotonía.




Gráfico 17. Calibración sin monotonía

El Brier Score, que quedó pendiente de leer en el apartado 6.1, vale sobre test 0,0957 en el WoE, 0,0611 en LightGBM y 0,0592 en XGBoost. Por Brier el orden sería XGBoost, LightGBM y, en último lugar, el modelo principal, al revés de lo que muestra la curva, donde el peor es LightGBM. La explicación es que el Brier no mide solo calibración, mezcla lo bien calibrado que está un modelo con lo afilado que es al separar clases, y castiga al WoE sobre todo por lo segundo, porque discrimina menos. La curva aísla la calibración, y ahí el modelo principal aguanta bien. El Brier alto del WoE no señala entonces un fallo de calibración, sino el coste de su menor poder de discriminación.

6.4. Estabilidad poblacional (PSI)

El Population Stability Index (PSI) mide cuánto cambia la distribución de los scores entre dos poblaciones. En este caso, entre el conjunto de entrenamiento y el de test aunque podría aplicarse a muestras post productivas. Funciona como una alerta temprana de inestabilidad: valores por debajo de 0,10 indican una distribución estable; entre 0,10 y 0,25, un cambio moderado que requiere vigilancia; y por encima de 0,25, un cambio significativo. El cálculo se realiza

segmentando los scores en deciles definidos sobre train y comparando la proporción de población de test que cae en cada tramo.

Modelo	PSI
WoE + RegLog	0,0027
LightGBM	0,0482
XGBoost	0,0172

Los tres quedan muy por debajo de 0,10, así que no hay desplazamiento poblacional entre las dos particiones. El modelo principal es el más estable, con un PSI casi nulo, por delante de XGBoost y de LightGBM, todos en zona estable.

Conviene situar el alcance de esta métrica. El PSI cobra su verdadero sentido en el backtesting, cuando se contrasta la cartera en producción contra la muestra con la que se construyó el modelo y se vigila la deriva a lo largo del tiempo.

6.5. Definición del umbral operativo (cost-sensitive)

Las métricas anteriores evalúan el modelo como una probabilidad continua, sin asumir todavía una decisión. Para convertir la PD en una decisión de aprobar o denegar hace falta fijar un umbral de corte. En lugar del 0,50 por defecto, que no encaja en un problema desbalanceado y con costes de error asimétricos, el umbral se define con un criterio cost-sensitive que pondera el coste relativo de los dos tipos de error.

En la concesión de crédito los dos errores de la matriz de confusión no cuestan lo mismo:

- Un falso negativo, conceder a quien luego incumple, deja una pérdida por la parte del importe que no se recupera.
- Un falso positivo, denegar a un cliente solvente, cuesta solo el margen que se renuncia a ganar.

El primero pesa mucho más: la pérdida de un impago, gobernada por la severidad o LGD, es varias veces el margen que se deja de ingresar al rechazar a un buen pagador. Sobre esa asimetría se fija un ratio de costes FN:FP = 4:1. No procede de calibrar un dato puntual de la cartera. Es una asunción de negocio razonable para el problema de originación.

A partir de ese ratio, el umbral óptimo de PD se obtiene como $c_{FP} / (c_{FP} + c_{FN}) = 1 / (1 + 4) = 0,20$. La regla de decisión deniega a todo cliente cuya PD estimada supere el 20%.

6.6. Métricas operativas bajo umbral Recall / Precision / F1

Aplicado el umbral de 0,20 a los tres modelos, se evalúa el rendimiento de la decisión binaria mediante la matriz de confusión y las métricas operativas derivadas.




Gráfico 18. Matriz de confusión de los tres modelos

El Recall ($TP / (TP + FN)$) mide la proporción de incumplimientos correctamente identificados; la Precision ($TP / (TP + FP)$), la proporción de aciertos entre las predicciones de incumplimiento; y el F1, la media armónica de ambas.

Modelo	Recall	Precision	F1
WoE + LogReg	0.8179	0.5309	0.6439
LightGBM	0.8207	0.7591	0.7887
XGBoost	0.8543	0.7126	0.7771

Tabla 19 - Métricas de Clasificación (Umbral 20%).

El ranking por F1 coloca a LightGBM (0,7887) por delante de XGBoost (0,7771) y, a bastante distancia, del modelo principal (0,6439). Lo que de verdad explica esa distancia se ve en el desglose. El recall es parecido en los tres, entre 0,82 y 0,85, así que todos detectan una proporción comparable de los incumplimientos reales. La diferencia se abre en la precisión donde el modelo principal se queda en 0,5309, mientras que los dos boosting se mueven entre 0,71 y 0,76. En términos de la matriz, el WoE acumula 258 falsos positivos frente a los 93 y 123 de los benchmark, es decir, rechaza a muchos más buenos pagadores para acabar identificando prácticamente los mismos incumplidores.

El motivo está en la forma de la distribución de PD de cada modelo. La del modelo principal es más suave y deja bastante masa en la franja intermedia, entre 0,20 y 0,50, de modo que muchos clientes caen justo alrededor del umbral y terminan denegados. Los boosting producen distribuciones más bimodales, con los buenos agolpados cerca de 0 y los malos cerca de 1, y dejan a pocos clientes en la zona de duda. El efecto se ve en la cobertura: el modelo principal marca como alto riesgo a cerca del 31% de la cartera, frente al 22 a 24% de los benchmark.




Gráfico 19. Distribución de PD de los tres modelos en test

Conviene recordar que estas métricas dependen del umbral fijado. Bajo el enfoque IRB el criterio para elegir el modelo no son ellas, sino la discriminación, la calibración y la estabilidad analizadas en los apartados anteriores.

6.7.Score Band Report del Modelo Principal

El Score Band Report traduce la PD del modelo principal, WoE más Regresión Logística, a una escala de puntuación operativa, herramienta habitual en la gestión de carteras de crédito. La conversión de PD a puntos sigue la convención estándar de scorecard (*Siddiqi*), donde a mayor PD corresponde menor puntuación, con los parámetros:

- Offset = 500,
- PDO (points to double the odds) = 20
- Factor resultante de $20 / \ln(2) \approx 28,85$.

La población se segmenta en diez bandas, deciles de puntos definidos sobre train, y para cada banda se contrasta la tasa de incumplimiento esperada, la PD media predicha, con la observada.

Banda (puntos)	PD esperada	N	N malos	% cartera	Tasa obs. malos	% aprob. acum.
361-479	0.8319	174	139	9.7%	0.7989	100.0%
479-516	0.5053	196	105	11.0%	0.5357	90.3%
516-541	0.2705	191	50	10.7%	0.2618	79.3%
541-560	0.1522	172	24	9.6%	0.1395	68.6%
560-574	0.0895	177	14	9.9%	0.0791	59.0%
574-587	0.0584	185	11	10.4%	0.0595	49.1%
587-599	0.0389	184	7	10.3%	0.0380	38.8%
599-611	0.0258	172	4	9.6%	0.0233	28.5%
611-623	0.0172	171	1	9.6%	0.0058	18.9%
623-670	0.0096	166	2	9.3%	0.0120	9.3%

Tabla 20 - Calibración y Bandas de Scoring (PD).

La PD esperada, que es la tasa de incumplimiento que predice el modelo, queda muy próxima a la observada en cada banda, tanto en test como en train, lo que confirma la buena calibración del modelo principal de forma desagregada: no sobreestima ni subestima el riesgo de manera sistemática a lo largo de las bandas. Los bordes de las bandas coinciden además entre train y test, algo coherente con el bajo PSI documentado en el apartado 6.4.

Trasladado el umbral cost-sensitive (PD = 0,20) a la escala de puntos, el corte se sitúa en 540 puntos: se aprueba a los clientes con 540 puntos o más y se deniega a los de menos de 540. A esa altura la política aprueba en torno al 69% de la cartera y deniega el 31% restante, en línea con el reparto que ya mostraba la matriz de confusión del apartado anterior.

6.8.Comparativa Principal vs Benchmark

La síntesis de las dimensiones evaluadas deja una disyuntiva bastante nítida. Los dos benchmark, LightGBM y XGBoost, mandan en discriminación y también en las métricas operativas bajo umbral, donde su mayor precisión se traduce en bastantes menos buenos pagadores rechazados. El modelo principal se queda detrás, pero es el más estable de los tres y mantiene una calibración sólida, con su curva pegada a la diagonal.

Modelo	AUC	Gini	KS	Brier	PSI	Recall	Precision	F1
WoE + RegLog	0.8915	0.7830	0.6426	0.0957	0.0027	0.8179	0.5309	0.6439
LightGBM	0.9547	0.9094	0.7831	0.0611	0.0482	0.8207	0.7591	0.7887
XGBoost	0.9552	0.9103	0.7768	0.0592	0.0172	0.8543	0.7126	0.7771

Tabla 21 - Resumen Global de Métricas de Desempeño y Estabilidad.

Entre los benchmark, ambos tienen la misma capacidad discriminatoria pero XGBoost calibra mejor. El Brier coloca al modelo principal en último lugar, pero como se vio en el apartado 6.3 eso responde a su menor poder de discriminación y no a un problema de calibración, ya que en la curva el WoE acompaña a XGBoost sobre la diagonal.

El modelo menos discriminante, el principal, es el más estable, y la ganancia de discriminación de los benchmark se paga con algo de estabilidad, de forma más clara en LightGBM. La calibración alimenta el cálculo de RWA y si el modelo dice que hay menos riesgo que el real se apartará menos provisiones de las que debería. De modo que la estabilidad poblacional y una PD bien calibrada pesan tanto como la discriminación pura. A esto se añade lo que ningún benchmark ofrece de forma nativa: el modelo principal es monótono por construcción y se lee banda a banda, y esa trazabilidad es la que termina de inclinar la balanza en un modelo destinado a capital y provisiones. La distancia en discriminación frente a los benchmark, aunque consistente, es manejable; la ventaja en estabilidad y transparencia es la que resulta determinante.

6.9.Recomendación final

Con todo lo anterior, el modelo que se propone para implementación operativa es el principal, WoE más Regresión Logística.

El razonamiento es este. Los benchmark marcan el techo de discriminación que el dataset permite, pero el modelo principal recupera buena parte de esa capacidad sin renunciar a lo que un modelo de capital y provisiones necesita: una PD bien calibrada, la población más estable de las tres y una estructura que se puede auditar tramo a tramo. La PD que entrega alimenta de forma fiable el cálculo del RWA y el provisionamiento bajo IFRS 9, y al ser monótono por construcción y traducirse en una tarjeta de puntuación, cualquier decisión queda explicable ante un cliente, un validador interno o un supervisor. Esa trazabilidad es difícil de igualar con un boosting, que aun forzando la monotonía sigue siendo una caja bastante más opaca.

La pérdida de discriminación frente a los benchmark existe y es consistente, pero se mantiene en un rango asumible. La discriminación adicional que ofrecerían no compensa su opacidad ni, en el caso de LightGBM, la menor estabilidad que conlleva. El punto de corte operativo se fija en 540 puntos, equivalente a una PD del 20%, bajo el criterio cost-sensitive que penaliza el falso negativo cuatro veces más que el falso positivo.

Nada de esto descarta los benchmark. Cumplen un papel claro como referencia del máximo discriminante alcanzable y como apoyo en usos donde la interpretabilidad no sea vinculante. Para el modelo que entra en el cálculo de capital y en la decisión de concesión, la transparencia, la calibración y la estabilidad del principal lo dejan como la opción más sólida.

6.10. Limitaciones

El análisis tiene varios límites que conviene declarar, porque acotan el alcance de las conclusiones.

- El AUC de entrenamiento igual a 1,0 en los boosting, aunque quedó auditado como propiedad estructural del HMEQ, deja al conjunto de train sin capacidad informativa

sobre la generalización de esos modelos, que ha habido que valorar apoyándose en validación cruzada y test.

- El PSI calculado solo comprueba que el split no introduce desplazamientos, no la deriva real de la cartera a lo largo del tiempo.
- El peso de DEBTINC y su ausencia no aleatoria son rasgos propios de estos datos. En producción el mecanismo de ausencia podría cambiar y alterar el comportamiento del modelo.
- HMEQ es un conjunto público, de tamaño limitado, un solo producto y origen estadounidense, por lo que las conclusiones no se trasladan sin más a otras carteras.
- El trabajo modela únicamente la PD. La LGD y la EAD quedan fuera, y con ellas la pérdida esperada ($EL = PD \times LGD \times EAD$), que se apunta como línea de continuación.

7. Conclusiones

El TFM planteó desarrollar y comparar modelos de application scoring estimando la PD de la muestra HMEQ, enfrentando un modelo estadístico y dos técnicas de gradient boosting. Durante el desarrollo la pregunta principal es si ¿compensa renunciar a la regresión logística clásica a cambio de la capacidad predictiva del gradient boosting?

En discriminación, ambos LightGBM y XGBoost ganan con AUC muy similar con 0,95. Si bien AUC en WoE es bueno, 0,89, la distancia entre ambos métodos es real. Sin embargo, un modelo de PD no se queda en ordenar clientes y su número entra en el cálculo del capital y de las provisiones, y ahí lo que pesa es que la probabilidad sea creíble y aguante en el tiempo. Hablamos de la calibración y la estabilidad.

En calibración el WoE sostiene la comparación de sobra: su curva sigue la diagonal casi sin separarse, señal de que la PD que entrega se corresponde con la frecuencia de impago observada. Por lo tanto, mantiene una dirección de riesgo coherente. En cambio, los modelos de boosting no calibran tan bien aunque XGBoost lo hace mejor que LightGBM.

Sobre la estabilidad, el PSI, aunque entre train y test solo anticipa lo que habría que vigilar en un backtesting real, apunta en la misma dirección y deja al modelo principal como el más estable de los tres.

Por todo ello el modelo que se propone para producción es la regresión logística con WoE. No por las métricas de discriminación, que no gana, sino por reunir, con una calibración tan buena como la del mejor boosting, la trazabilidad y la estabilidad que un modelo de capital y provisiones necesita.

Del trabajo con los datos quedan dos hallazgos que conviene recordar. DEBTINC falta en el 66 % de los impagos y solo en el 10 % de los clientes sanos, así que su ausencia ya informa del riesgo. Eso explica buena parte de lo que consiguen los boosting, que tratan el missing sin imputarlo, y no es una fuga de información porque el dato falta en el momento mismo de la solicitud. El otro es el AUC de 1 sobre entrenamiento, que a primera vista preocupa. No es un fallo. Se repite con cualquier nivel de regularización y no daña la generalización que confirman el test y la validación cruzada. Es una propiedad del HMEQ, no del modelo.

Para convertir la probabilidad en una decisión hizo falta un corte. Se fijó penalizando el falso negativo cuatro veces más que el falso positivo, lo que lleva el umbral a una PD del 20 %, que aprueba en torno al 69 % de la cartera. Importante marcar que esto es una asunción de negocio, no un parámetro calibrado contra un dato concreto.

El objetivo se cumple. Se midió el precio en discriminación de elegir el modelo más defendible ante el regulador y se llegó a una recomendación con fundamento. Los boosting marcan el techo de lo que el dataset deja discriminar; el WoE es el que se sostiene cuando el modelo tiene que alimentar capital y provisiones.

Queda camino por delante. Aquí solo se modela la PD, y la pérdida esperada necesita además la severidad y la exposición en el momento del impago para cerrar la cuenta de $EL = PD \times LGD \times EAD$, que es la que termina en las provisiones de IFRS 9. La validación también admite otra vuelta: el PSI entre train y test solo anticipa lo que habría que vigilar, y un ejercicio out-of-time mediría la deriva real de la cartera a lo largo del tiempo. Por último, el alcance se ha ceñido a un dataset público de un solo producto y un único mercado, así que llevarlo a una cartera real y más variada es lo que diría de verdad si las conclusiones viajan.

8. Anexos

8.1. Anexo A. Repositorio del proyecto (GitHub)

El código completo del trabajo es público y está disponible bajo licencia MIT en el siguiente repositorio, que contiene los cinco notebooks (EDA, modelo principal y los dos benchmark, y la comparación), el módulo `src/` con los transformadores propios, los modelos serializados en `models/` y los datos.

<https://github.com/Karimhh8/tfm-data-science-credit-risk-karim>

9. Bibliografía

Baesens, B., Roesch, D. y Scheule, H. (2016). *Credit Risk Analytics: Measurement Techniques, Applications, and Examples in SAS*. Wiley.

Siddiqi, N. (2017). *Intelligent Credit Scoring: Building and Implementing Better Credit Risk Scorecards* (2.ª ed.). Wiley.

Thomas, L. C., Edelman, D. B. y Crook, J. N. (2002). *Credit Scoring and Its Applications*. Society for Industrial and Applied Mathematics (SIAM).

Autoridad Bancaria Europea (EBA) (2017). Directrices sobre la estimación de la PD, la estimación de la LGD y el tratamiento de las exposiciones en situación de impago (EBA/GL/2017/16).

Parlamento Europeo y Consejo (2013). Reglamento (UE) n.º 575/2013 sobre los requisitos prudenciales de las entidades de crédito y las empresas de inversión (CRR).

Banco Central Europeo (BCE) (2019). Instructions for reporting the validation results of internal models: credit risk (véase Anexo C).

CreditRiskAnalytics.net. Dataset HMEQ (Home Equity Loans). Material complementario de Baesens, Roesch y Scheule (2016). <http://www.creditriskanalytics.net/>

ⁱ Datos disponibles en <http://www.creditriskanalytics.net/> o <https://github.com/Karimhh8/tfm-data-science-credit-risk-karim>